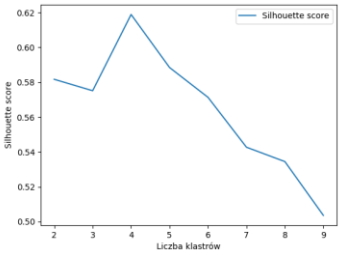
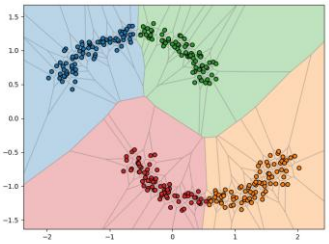
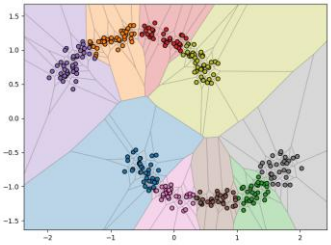
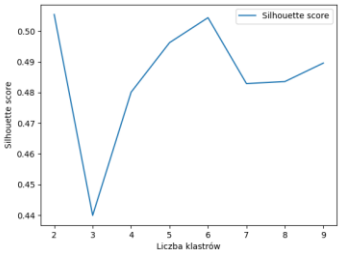
2_1.csv

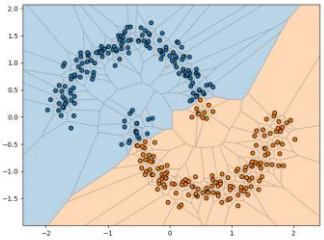


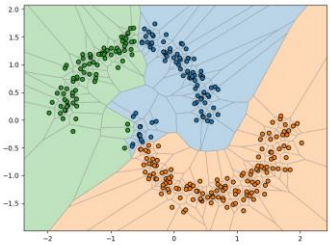




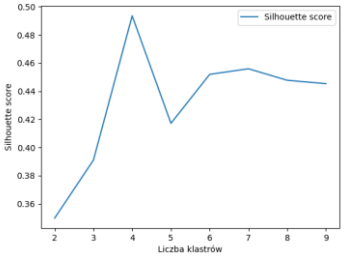
2_2.csv

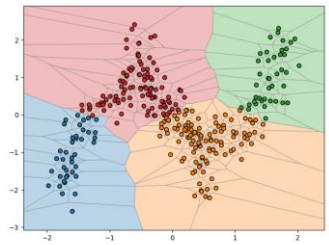


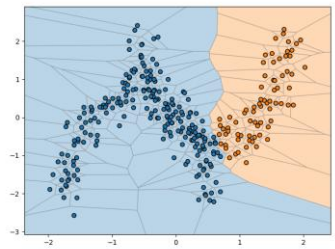




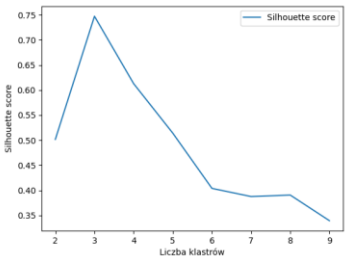
2_3.csv

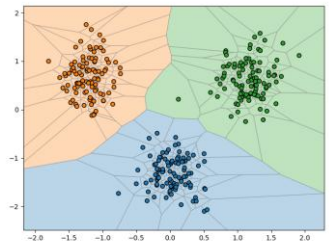


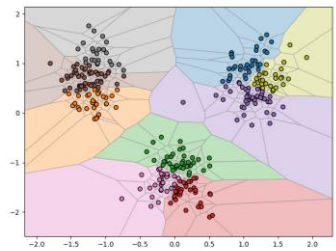




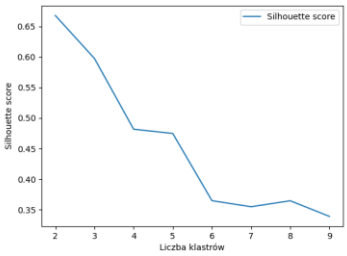
3_1.csv

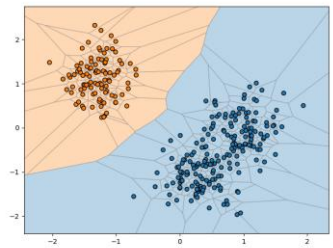


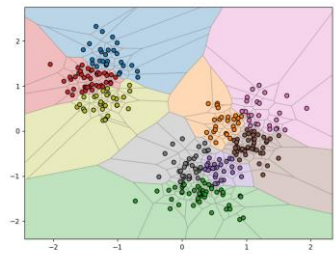




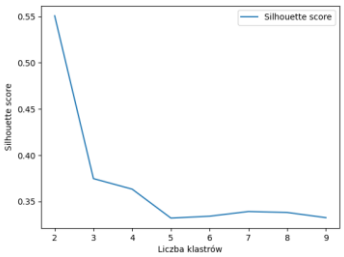
3_2.csv

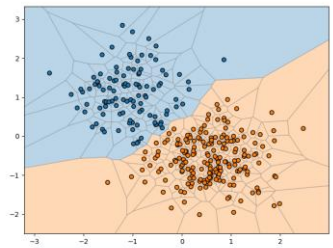


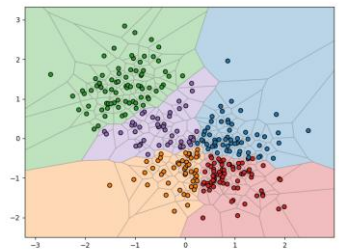




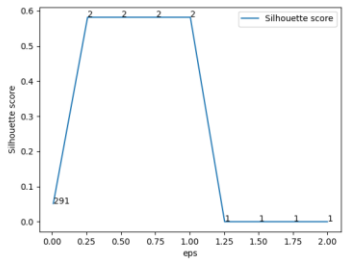
3_3.csv

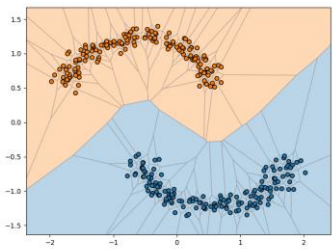


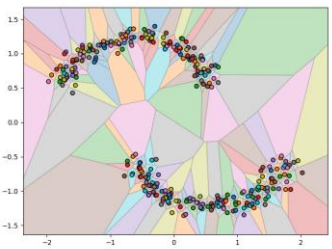




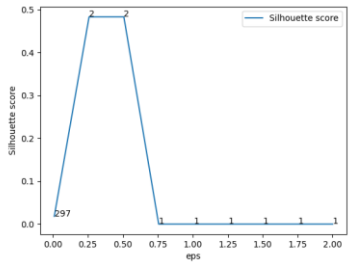
2_1.csv

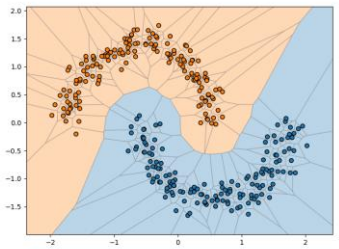


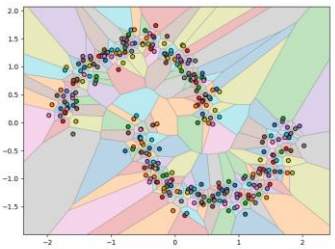




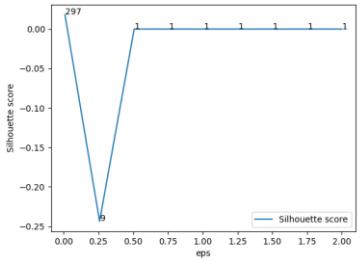
2_2.csv

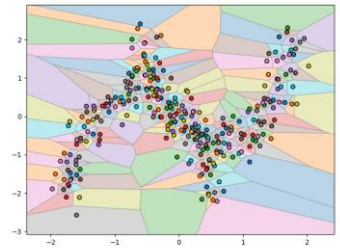


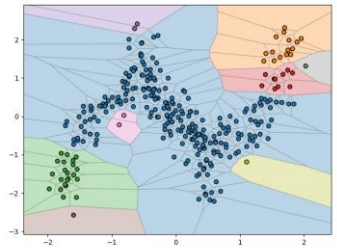




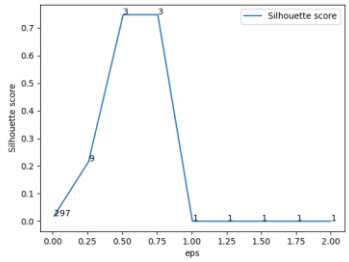
2_3.csv

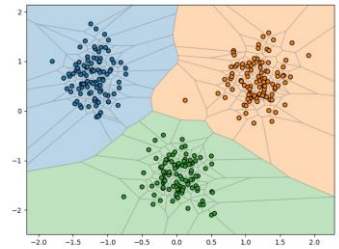


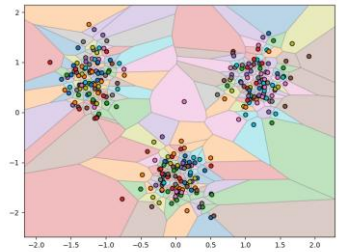




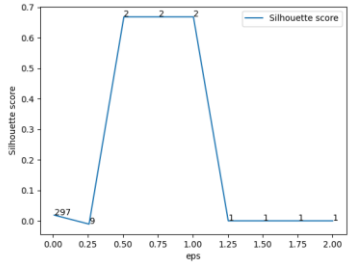
3_1.csv

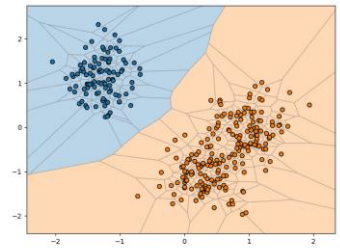


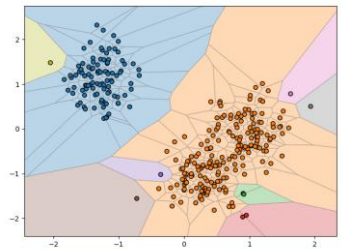




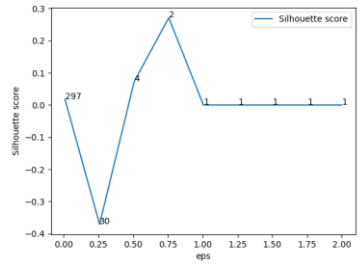
3_2.csv

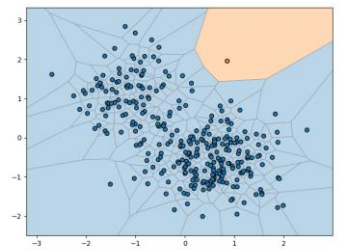


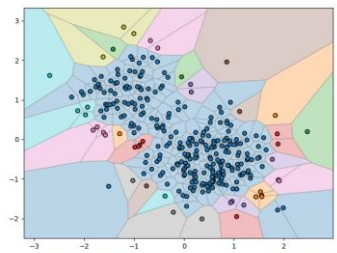




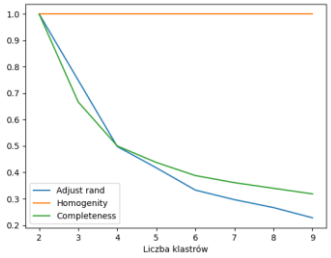
3_3.csv

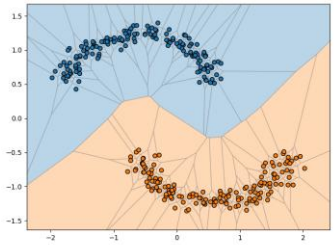


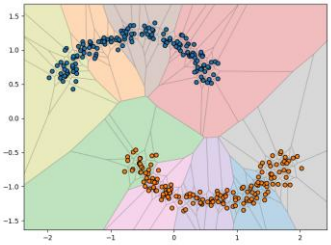




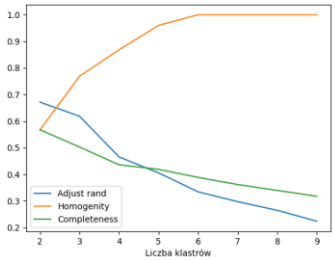
2_1.csv

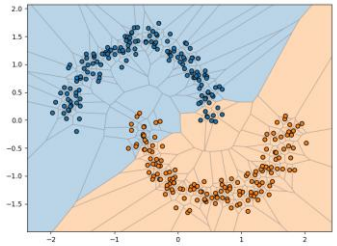


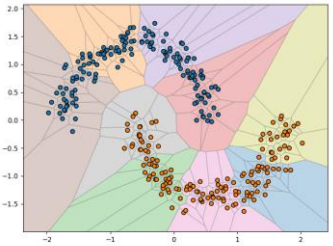




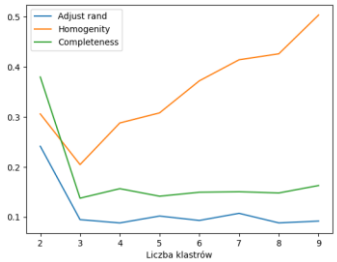
2_2.csv

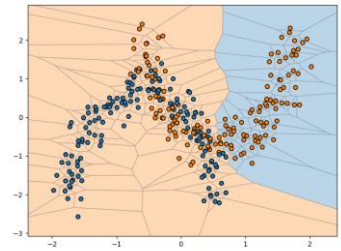


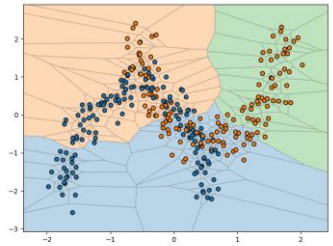




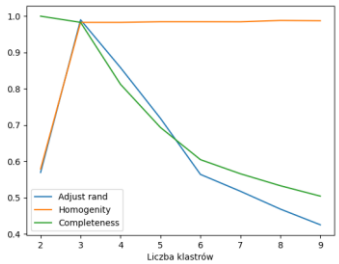
2_3.csv

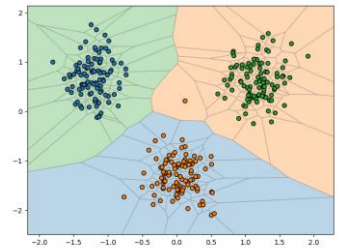


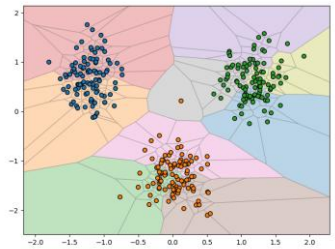




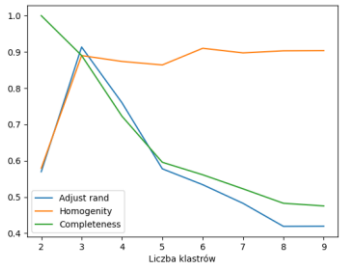
3_1.csv

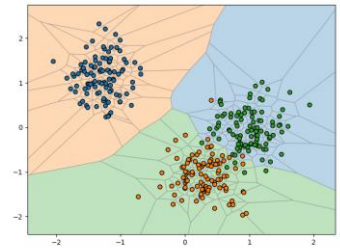


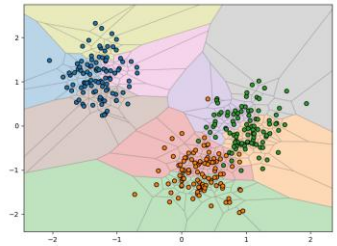




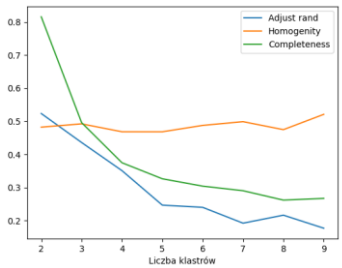
3_2.csv

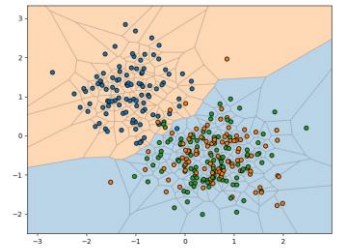


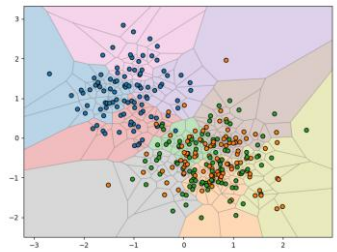




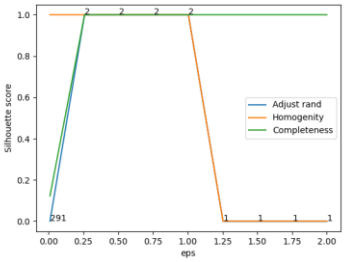
3_3.csv

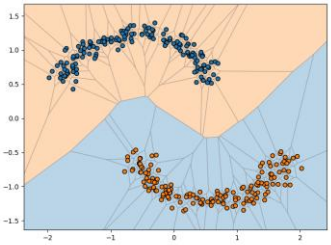


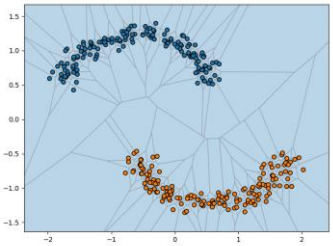




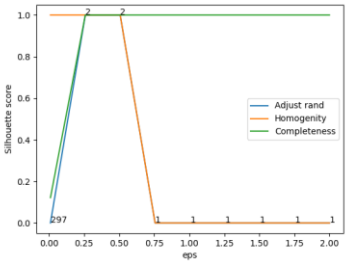
2_1.csv

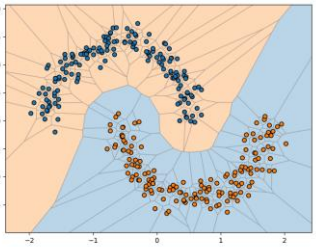


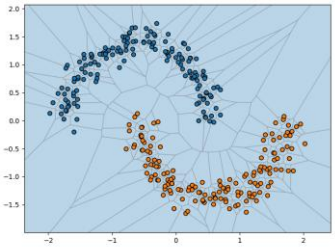




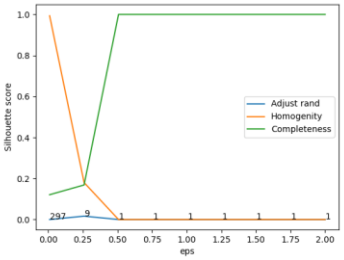
2_2.csv

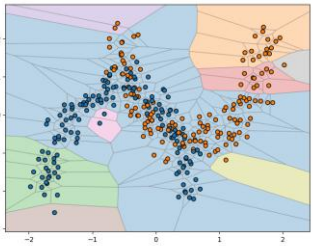


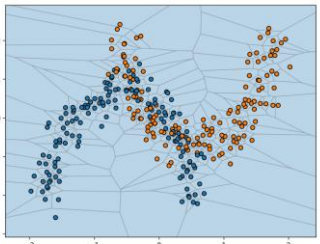




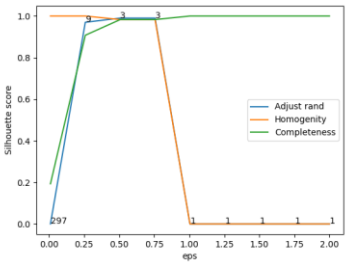
2_3.csv

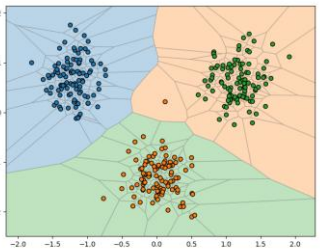


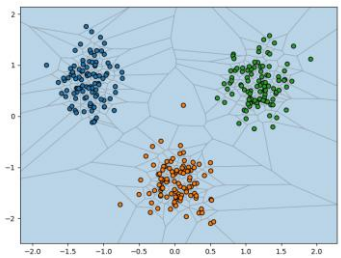




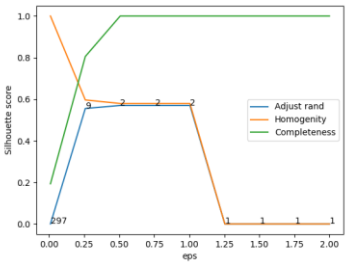
3_1.csv

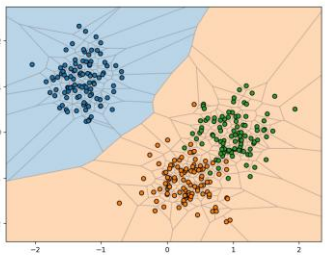


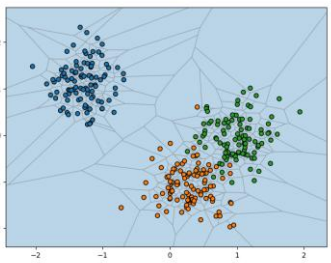




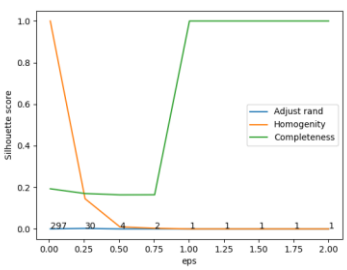
3_2.csv

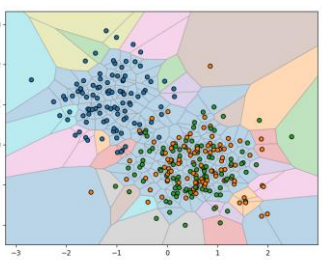


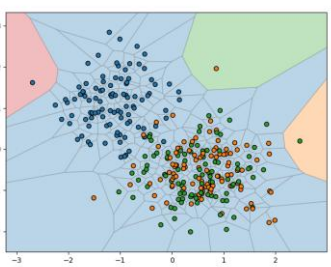




3_3.csv







Na potrzeby podsumowania wyników uzyskanych w eksperymencie 1 oraz 2, liczba klastrów będzie opisywana poprzez parametr k.

Wnioski na podstawie miary silhoutte score (eksperyment 1)

Wnioski dla algorytmu kmeans:

- Optymalna liczba klastrów odpowiada maksymalnej wartości silhouette score. Dla przykładu w zbiorze 1 najlepszy wynik uzyskano dla k = 4 (≈ 0.62), a w zbiorze 4 dla k = 3 (≈ 0.75). W przypadku braku wizualizacji wyników należy wybrać k, które pozwala uzyskać najwyższą wartość miary silhouette score.
- Jeżeli wartości silhouette score są podobne dla wielu wartości k, struktura danych jest niejednoznaczna, a liczba klastrów nie jest dobrze określona, np. w zbiorze 2. Nie wszystkie zbiory posiadają wyraźne maksimum silhouette score.

Wnioski dla algorytmu dbscan:

- Zbyt duże eps prowadzi do utworzenia wyłącznie jednego klastra, co uniemożliwia obliczenie miary silhouette score.
- Zbyt małe eps (≈ 0) prowadzi do utworzenia zbyt dużej liczby klastrów, przy silhouette score bliskim 0, np. w zbiorze numer 6 (≈ 0.018).
- Poprawna struktura klastrów pojawia się tylko w wąskim przedziale wartości eps, co oznacza wysoką wrażliwość algorytmu na ten parametr.
- Niskie wartości silhouette score, nawet przy zmianie eps, sugerują brak wyraźnej struktury gęstościowej danych, np. w zbiorach 3 i 6.

Wnioski ogólne:

- Wysokie wartości silhoutte score wskazują na dobrze rozdzielone klastry.
- Niskie wartości silhoutte score (bliskie 0.00) sugerują brak wyraźnych skupisk.
- Ujemne wartości silhouette score oznaczają błędne przypisanie do klastrów, np. w zbiorze 3 dla algorytmu DBSCAN i eps = 0.26.

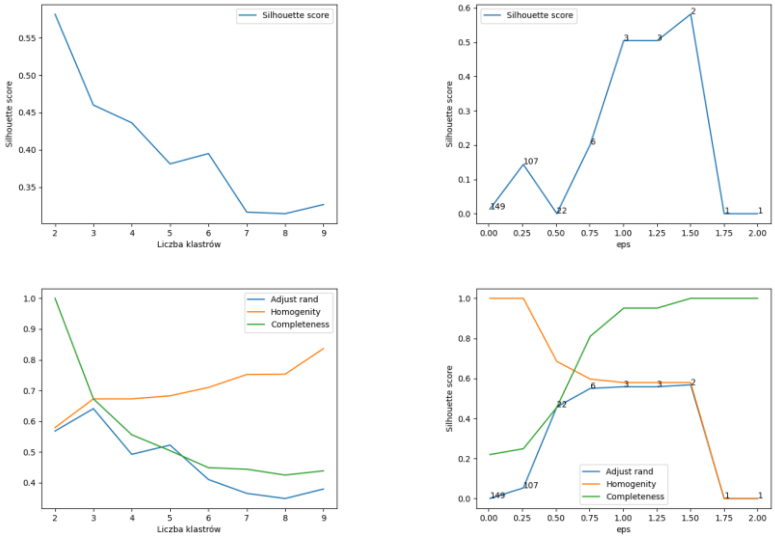
Wnioski na podstawie miar adjusted rand score, homogeneity score oraz completeness score (eksperyment 2)

Wnioski ogólne:

- Adjusted Rand Score najlepiej odzwierciedla zgodność między klastrami a etykietami. Wartość bliska 1 oznacza idealną separację klas (np. zbiór 1 i 4 dla optymalnych parametrów w KMeans i DBSCAN).
- Maksymalna wartość silhouette score nie zawsze odpowiada najlepszemu dopasowaniu do rzeczywistych etykiet – może wskazywać inną liczbę klastrów niż ta, dla której Adjusted Rand Score jest najwyższy.
- Wysoka homogeneity nie gwarantuje dobrej separacji klas – może oznaczać nadmierne rozdrobnienie danych. Na przykład w DBSCAN przy małym eps w zbiorach 1 i 2, przy jednoczesnym niskim Adjusted Rand Score, oznacza to, że klastry zawierają obiekty tylko jednej klasy, ale jest ich zbyt wiele.
- Niska completeness (np. w wynikach KMeans dla dużych wartości k) oznacza zbyt dużą liczbę klastrów.
- Wysoka homogeneity przy niskiej completeness oznacza nadmierne rozdrobnienie klastrów.
- Niska homogeneity przy wysokiej completeness oznacza zbyt małą liczbę klastrów.
- Zwiększanie liczby klastrów może prowadzić do nadmiernego dopasowania, w którym klastry są jednorodne, ale nie odpowiadają rzeczywistej strukturze danych.
- Żadna z miar nie jest wystarczająca samodzielnie – dopiero ich łączna analiza pozwala ocenić separowalność klas.
- Zbiory różnią się stopniem separowalności klas: od dobrze separowalnych (1, 4), przez częściowo (2, 5), do słabo separowalnych (3, 6).

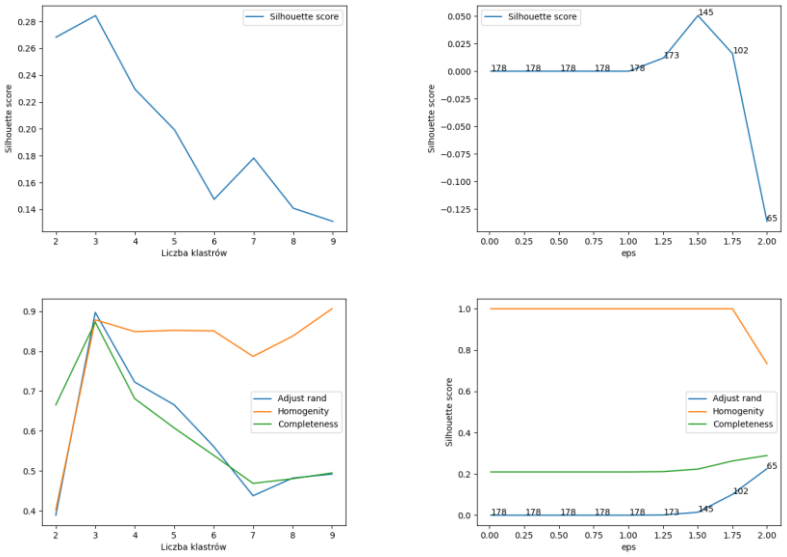
Analiza zbioru IRIS

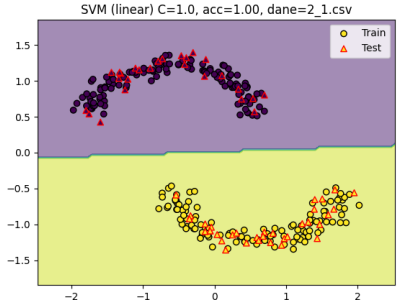
Najwyższy silhouette score uzyskano dla k = 2 (0.58), jednak najlepsza zgodność z etykietami występuje dla k = 3 (ARI ≈ 0.65), co odpowiada rzeczywistej liczbie klas. Zgodnie z wcześniejszymi wnioskami, najwyższy silhouette score nie zawsze oznacza najlepsze dopasowanie do struktury danych. Wraz ze wzrostem k obserwuje się spadek silhouette i ARI, co wskazuje na rozbijanie naturalnych grup. W DBSCAN małe eps prowadzi do wielu klastrów i niskiej jakości (ARI ≈ 0), natomiast poprawna struktura pojawia się tylko w wąskim zakresie eps (≈ 1.00–1.50), co potwierdza wysoką wrażliwość algorytmu. Zbiór IRIS cechuje się umiarkowaną separowalnością – klasy nie są idealnie rozłączne, ale tworzą wyraźne skupiska.

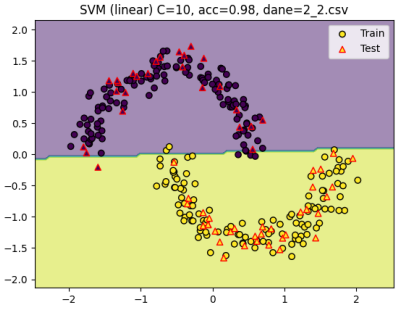


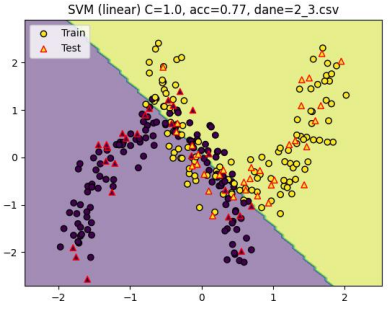
Analiza zbioru Wine

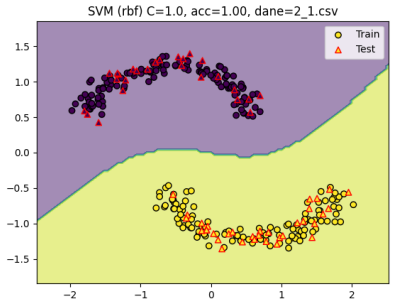
Niski silhouette score (maks. ≈ 0.28 dla k = 3) wskazuje na słabą separację klastrów. Jednocześnie najlepszą zgodność z etykietami uzyskano dla k = 3 (ARI ≈ 0.90), co – zgodnie z wcześniejszymi wnioskami – pokazuje, że poprawna liczba klastrów nie zawsze odpowiada maksimum silhouette score. DBSCAN tworzy bardzo dużą liczbę klastrów w szerokim zakresie eps (np. 178 dla małych eps i 65 dla eps = 2.0), co wskazuje na brak wyraźnej struktury gęstościowej danych. W efekcie zbiór Wine charakteryzuje się słabą separowalnością klas i większym nakładaniem się klas niż w IRIS.

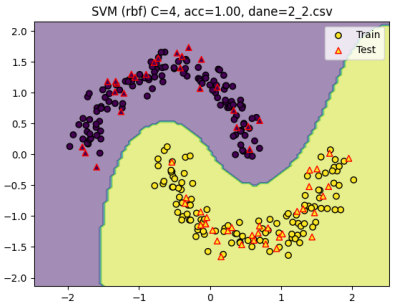


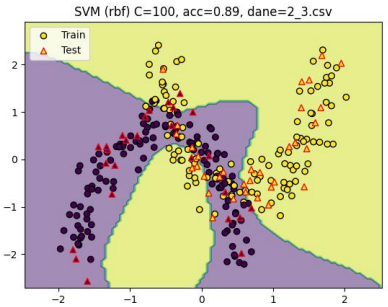

SVM (linear) C=1.0, acc=1.00, dane=2_1.csv
Train
Test

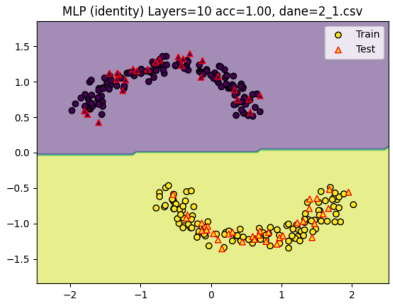

SVM (linear) C=10, acc=0.98, dane=2_2.csv
Train
Test

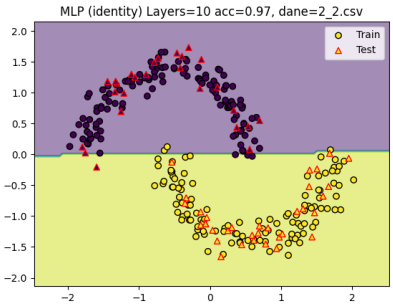

SVM (linear) C=1.0, acc=0.77, dane=2_3.csv
Train
Test

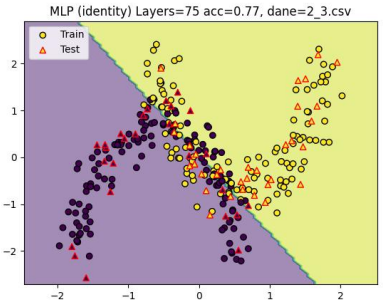

SVM (rbf) C=1.0, acc=1.00, dane=2_1.csv
Train
Test

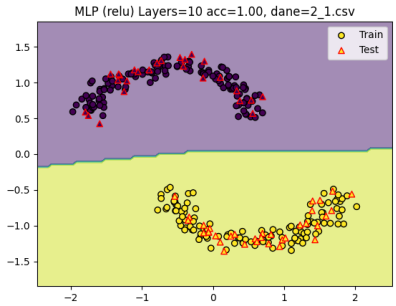

SVM (rbf) C=4, acc=1.00, dane=2_2.csv
Train
Test

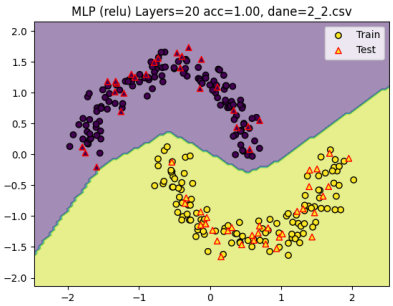

SVM (rbf) C=100, acc=0.89, dane=2_3.csv
Train
Test

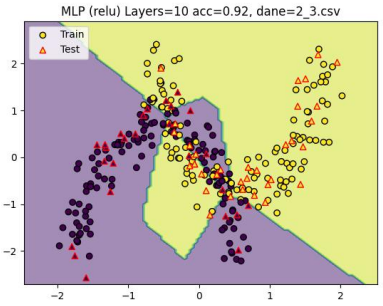

MLP (identity) Layers=10 acc=1.00, dane=2_1.csv
Train
Test

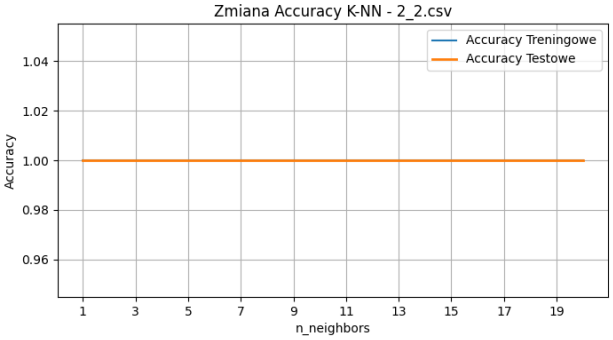

MLP (identity) Layers=10 acc=0.97, dane=2_2.csv
Train
Test

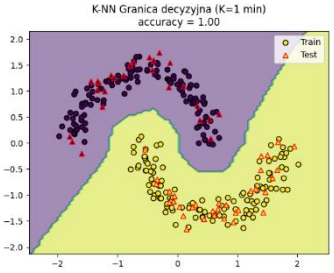

MLP (identity) Layers=75 acc=0.77, dane=2_3.csv
Train
Test

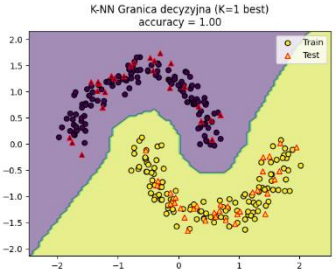

MLP (relu) Layers=10 acc=1.00, dane=2_1.csv
Train
Test

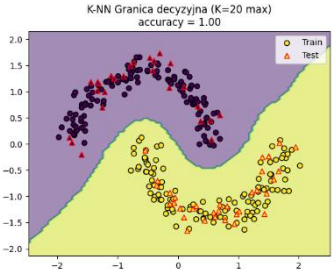

MLP (relu) Layers=20 acc=1.00, dane=2_2.csv
Train
Test

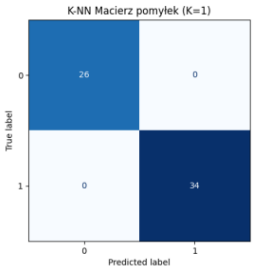

MLP (relu) Layers=10 acc=0.92, dane=2_3.csv
Train
Test

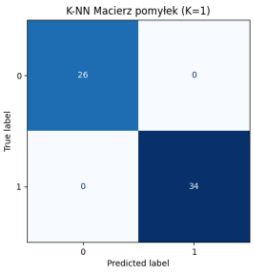

Zmiana Accuracy K-NN - 2_2.csv
Accuracy Treningowe
Accuracy Testowe
Accuracy
n_neighbors

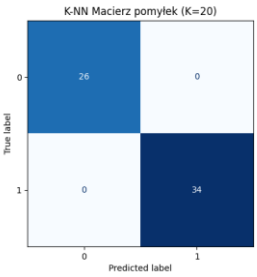

K-NN Granica decyzyjna (K=1 min)
accuracy = 1.00
Train
Test

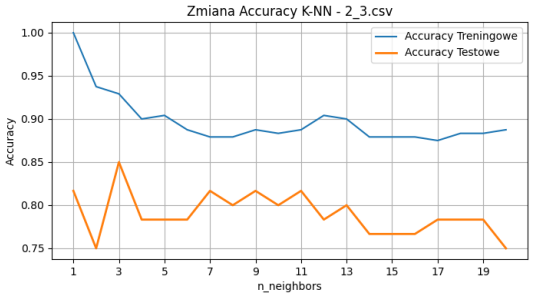

K-NN Granica decyzyjna (K=1 best)
accuracy = 1.00
Train
Test

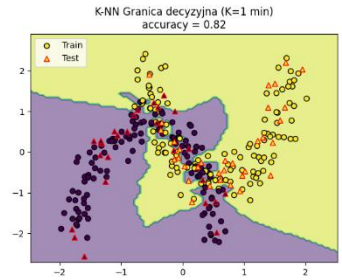

K-NN Granica decyzyjna (K=20 max)
accuracy = 1.00
Train
Test

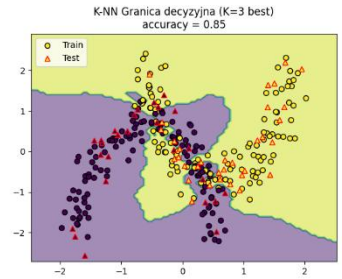

K-NN Macierz pomyłek (K=1)
26
0
0
34
True label
Predicted label

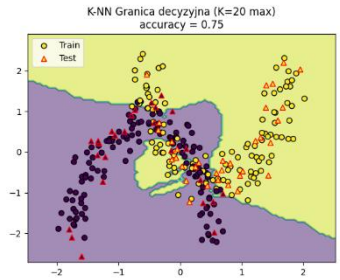

K-NN Macierz pomyłek (K=1)
26
0
0
34
True label
Predicted label

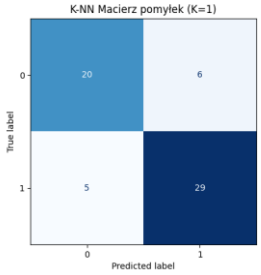

K-NN Macierz pomyłek (K=20)
26
0
0
34
True label
Predicted label

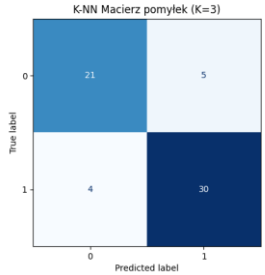

Zmiana Accuracy K-NN - 2_3.csv
Accuracy Treningowe
Accuracy Testowe
Accuracy
n_neighbors

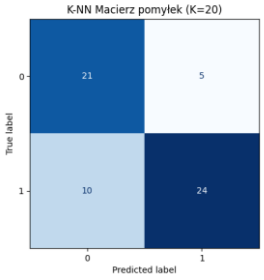

K-NN Granica decyzyjna (K=1 min)
accuracy = 0.82
Train
Test

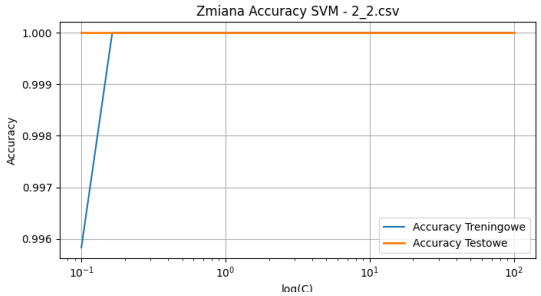

K-NN Granica decyzyjna (K=3 best)
accuracy = 0.85
Train
Test

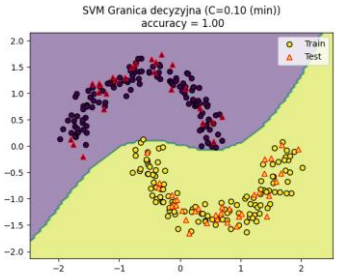

K-NN Granica decyzyjna (K=20 max)
accuracy = 0.75
Train
Test

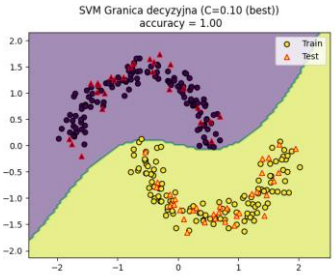

K-NN Macierz pomyłek (K=1)
20
6
5
29
True label
Predicted label

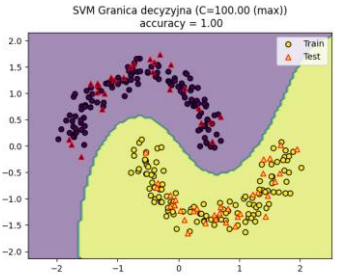

K-NN Macierz pomyłek (K=3)
21
5
4
30
True label
Predicted label

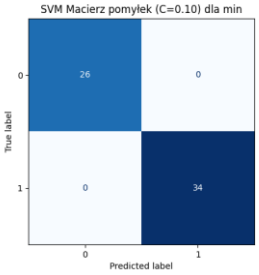

K-NN Macierz pomyłek (K=20)
21
5
10
24
True label
Predicted label

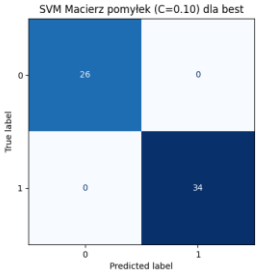

Zmiana Accuracy SVM - 2_2.csv
Accuracy
log(C)
Accuracy Treningowe
Accuracy Testowe

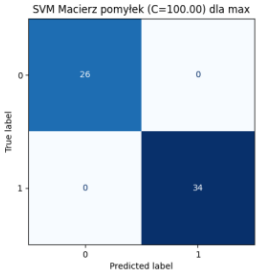

SVM Granica decyzyjna (C=0.10 (min))
accuracy = 1.00
Train
Test

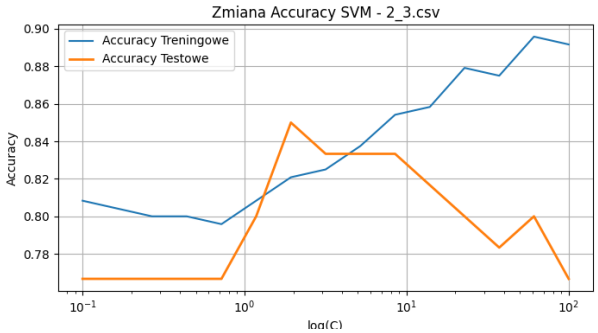

SVM Granica decyzyjna (C=0.10 (best))
accuracy = 1.00
Train
Test

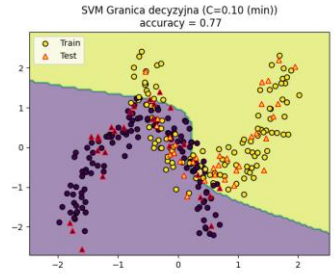

SVM Granica decyzyjna (C=100.00 (max))
accuracy = 1.00
Train
Test

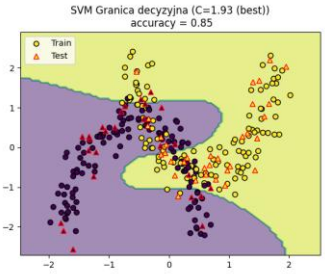

SVM Macierz pomyłek (C=0.10) dla min
True label
Predicted label
26
0
0
34

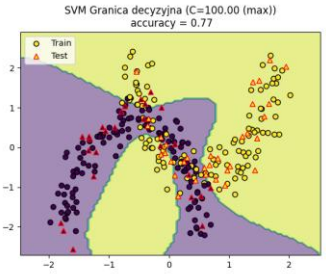

SVM Macierz pomyłek (C=0.10) dla best
True label
Predicted label
26
0
0
34

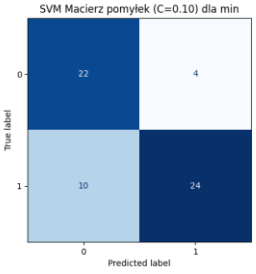

SVM Macierz pomyłek (C=100.00) dla max
True label
Predicted label
26
0
0
34

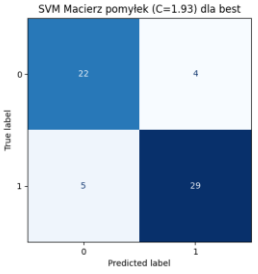

Zmiana Accuracy SVM - 2_3.csv
Accuracy
log(C)
Accuracy Treningowe
Accuracy Testowe

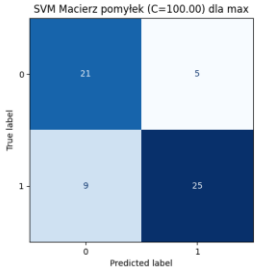

SVM Granica decyzyjna (C=0.10 (min))
accuracy = 0.77
Train
Test

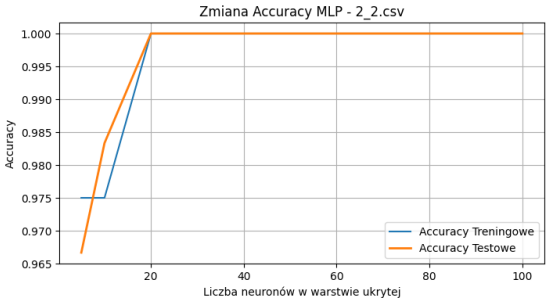

SVM Granica decyzyjna (C=1.93 (best))
accuracy = 0.85
Train
Test

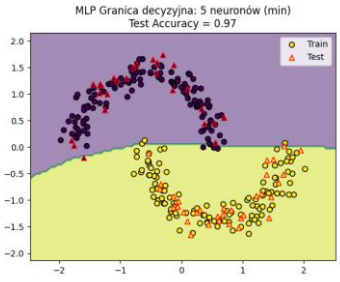

SVM Granica decyzyjna (C=100.00 (max))
accuracy = 0.77
Train
Test

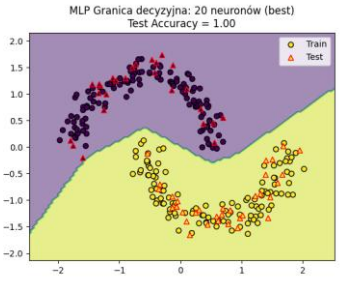

SVM Macierz pomyłek (C=0.10) dla min
True label
Predicted label
22
4
10
24

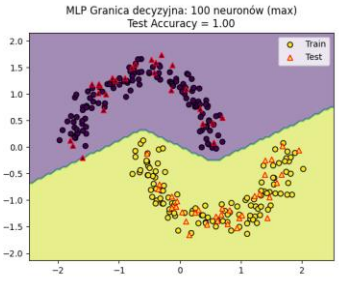

SVM Macierz pomyłek (C=1.93) dla best
True label
Predicted label
22
4
5
29

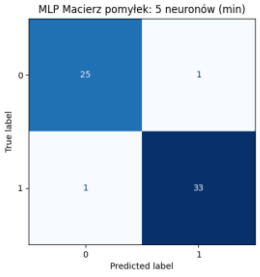

SVM Macierz pomyłek (C=100.00) dla max
True label
Predicted label
21
5
9
25

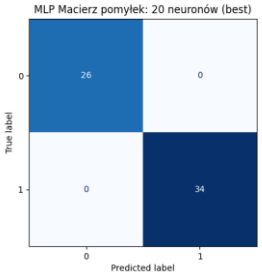

Zmiana Accuracy MLP - 2_2.csv
Accuracy
Liczba neuronów w warstwie ukrytej
Accuracy Treningowe
Accuracy Testowe

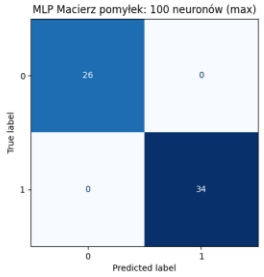

MLP Granica decyzyjna: 5 neuronów (min)
Test Accuracy = 0.97
Train
Test

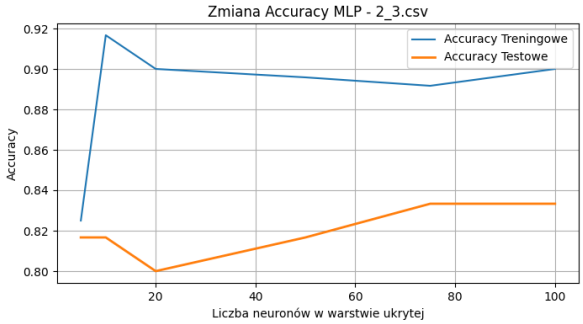

MLP Granica decyzyjna: 20 neuronów (best)
Test Accuracy = 1.00
Train
Test

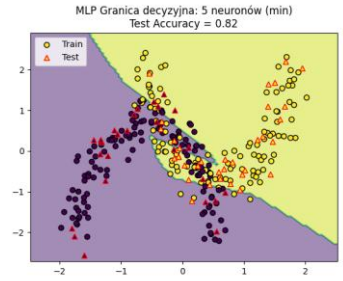

MLP Granica decyzyjna: 100 neuronów (max)
Test Accuracy = 1.00
Train
Test

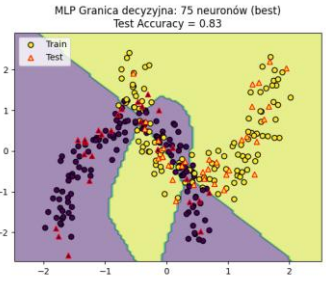

MLP Macierz pomyłek: 5 neuronów (min)
True label
Predicted label
25
1
1
33

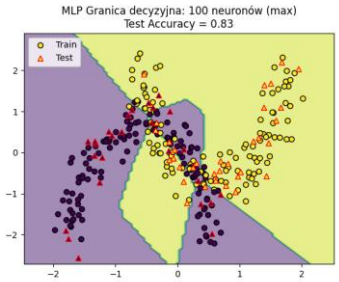

MLP Macierz pomyłek: 20 neuronów (best)
True label
Predicted label
26
0
0
34

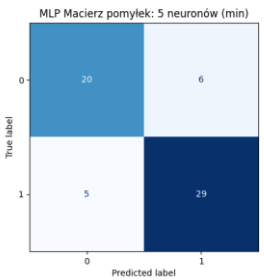

MLP Macierz pomyłek: 100 neuronów (max)
True label
Predicted label
26
0
0
34

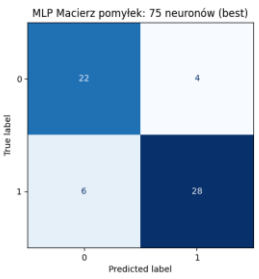

Zmiana Accuracy MLP - 2_3.csv
Accuracy
Liczba neuronów w warstwie ukrytej
Accuracy Treningowe
Accuracy Testowe

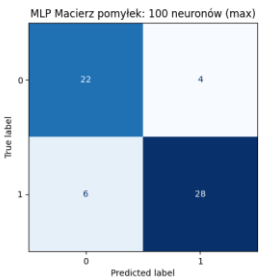

MLP Granica decyzyjna: 5 neuronów (min)
Test Accuracy = 0.82
Train
Test

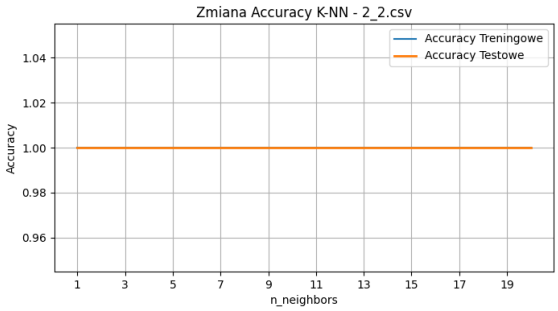

MLP Granica decyzyjna: 75 neuronów (best)
Test Accuracy = 0.83
Train
Test

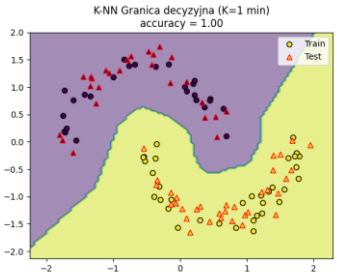

MLP Granica decyzyjna: 100 neuronów (max)
Test Accuracy = 0.83
Train
Test

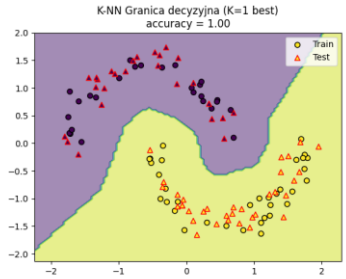

MLP Macierz pomyłek: 5 neuronów (min)
True label
Predicted label
20
6
5
29

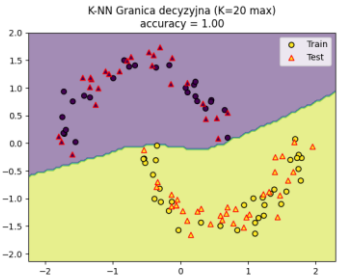

MLP Macierz pomyłek: 75 neuronów (best)
True label
Predicted label
22
4
6
28

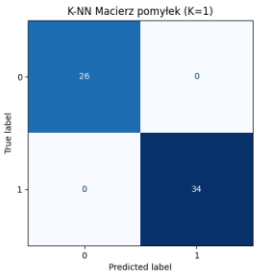

MLP Macierz pomyłek: 100 neuronów (max)
True label
Predicted label
22
4
6
28

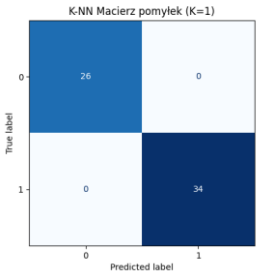

Zmiana Accuracy K-NN - 2_2.csv
Accuracy Treningowe
Accuracy Testowe
Accuracy
n_neighbors

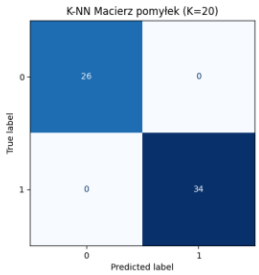

K-NN Granica decyzyjna (K=1 min)
accuracy = 1.00
Train
Test

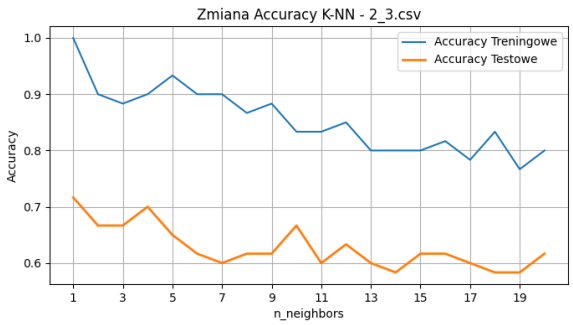

K-NN Granica decyzyjna (K=1 best)
accuracy = 1.00
Train
Test

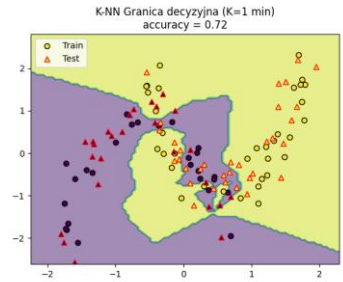

K-NN Granica decyzyjna (K=20 max)
accuracy = 1.00
Train
Test

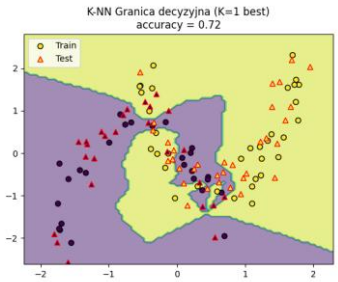

K-NN Macierz pomyłek (K=1)
26
0
0
34
True label
Predicted label

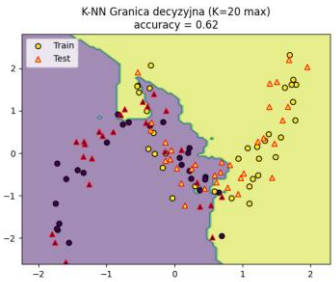

K-NN Macierz pomyłek (K=1)
26
0
0
34
True label
Predicted label

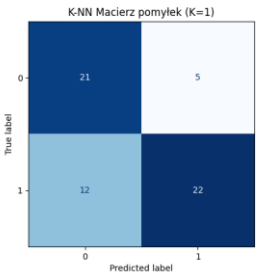

K-NN Macierz pomyłek (K=20)
26
0
0
34
True label
Predicted label

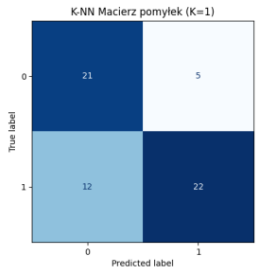

Zmiana Accuracy K-NN - 2_3.csv
Accuracy Treningowe
Accuracy Testowe
Accuracy
n_neighbors

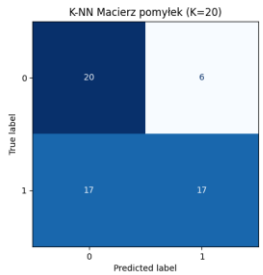

K-NN Granica decyzyjna (K=1 min)
accuracy = 0.72
Train
Test

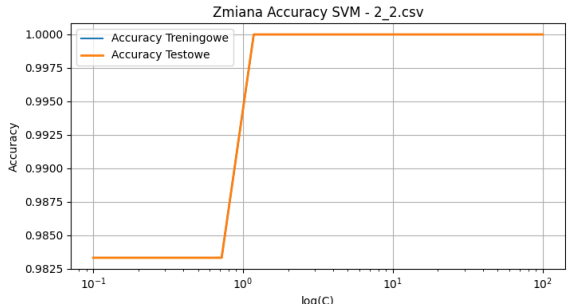

K-NN Granica decyzyjna (K=1 best)
accuracy = 0.72
Train
Test

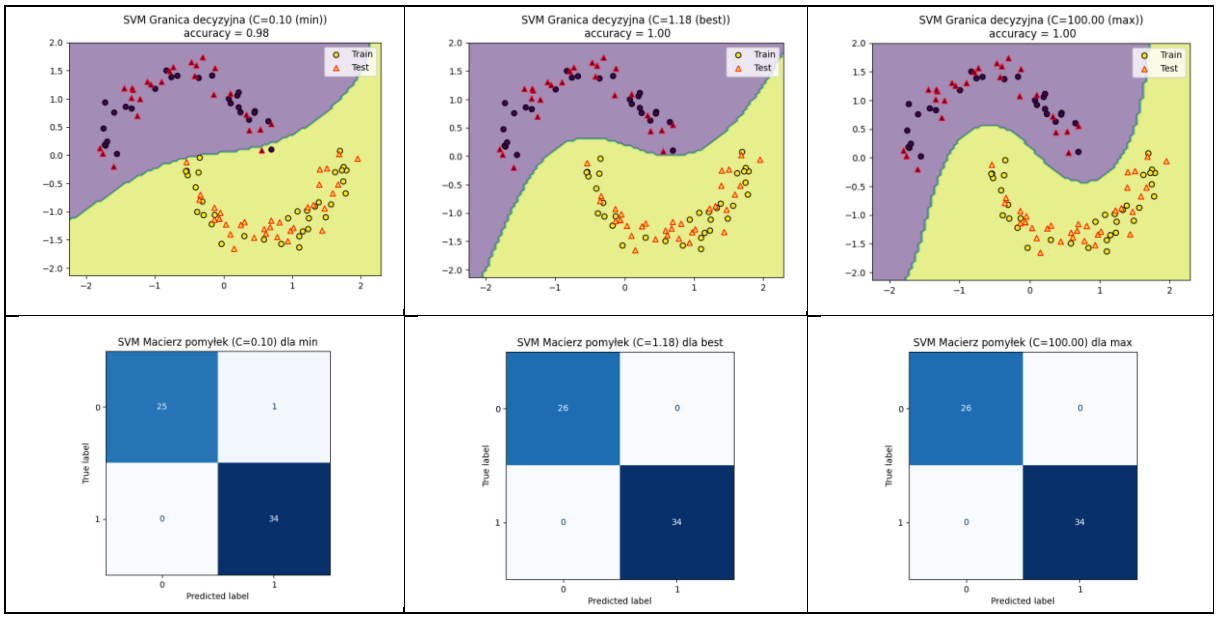

K-NN Granica decyzyjna (K=20 max)
accuracy = 0.62
Train
Test

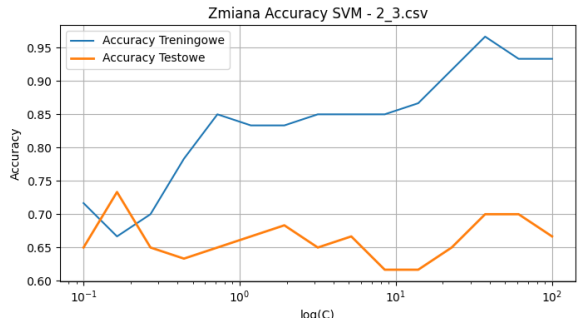

K-NN Macierz pomyłek (K=1)
21
5
12
22
True label
Predicted label

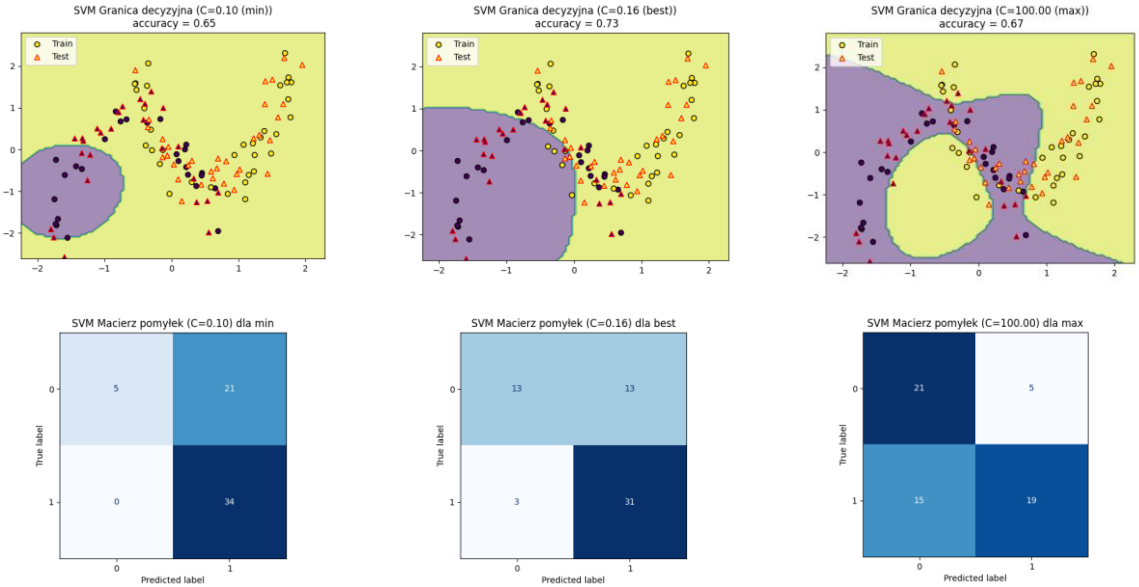

K-NN Macierz pomyłek (K=1)
21
5
12
22
True label
Predicted label

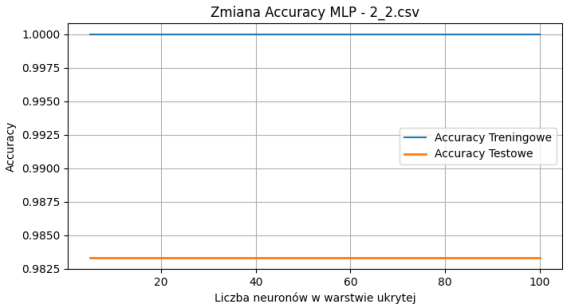

K-NN Macierz pomyłek (K=20)
20
6
17
17
True label
Predicted label

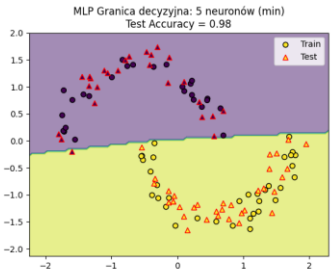

Zmiana Accuracy SVM - 2_2.csv
Accuracy Treningowe
Accuracy Testowe
Accuracy
log(C)

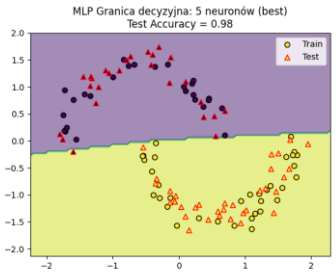

SVM Granica decyzyjna (C=0.10 (min))
accuracy = 0.98
SVM Granica decyzyjna (C=1.18 (best))
accuracy = 1.00
SVM Granica decyzyjna (C=100.00 (max))
accuracy = 1.00
Train
Test
SVM Macierz pomyłek (C=0.10) dla min
SVM Macierz pomyłek (C=1.18) dla best
SVM Macierz pomyłek (C=100.00) dla max
True label
Predicted label

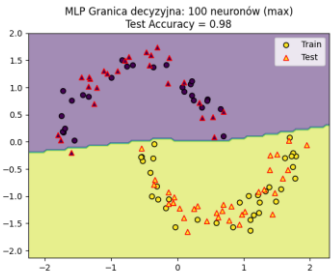

Zmiana Accuracy SVM - 2_3.csv
Accuracy Treningowe
Accuracy Testowe
Accuracy
log(C)

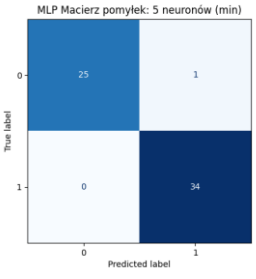

SVM Granica decyzyjna (C=0.10 (min))
accuracy = 0.65
SVM Granica decyzyjna (C=0.16 (best))
accuracy = 0.73
SVM Granica decyzyjna (C=100.00 (max))
accuracy = 0.67
Train
Test
SVM Macierz pomyłek (C=0.10) dla min
SVM Macierz pomyłek (C=0.16) dla best
SVM Macierz pomyłek (C=100.00) dla max
True label
Predicted label

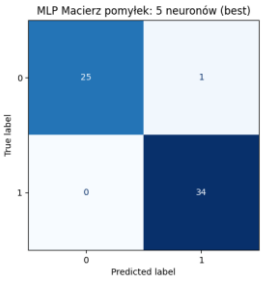

Zmiana Accuracy MLP - 2_2.csv
Accuracy
Liczba neuronów w warstwie ukrytej
Accuracy Treningowe
Accuracy Testowe

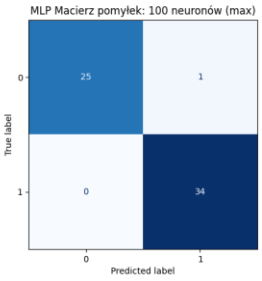

MLP Granica decyzyjna: 5 neuronów (min)
Test Accuracy = 0.98
Train
Test

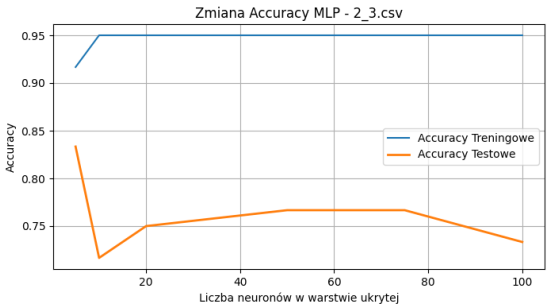

MLP Granica decyzyjna: 5 neuronów (best)
Test Accuracy = 0.98
Train
Test

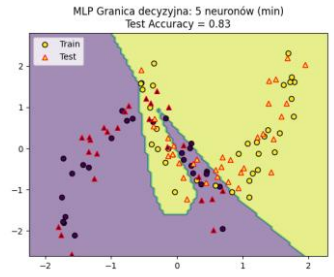

MLP Granica decyzyjna: 100 neuronów (max)
Test Accuracy = 0.98
Train
Test

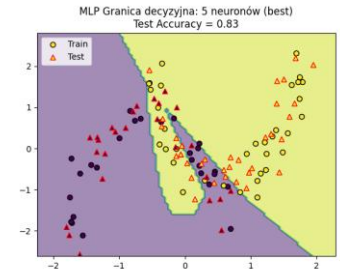

MLP Macierz pomyłek: 5 neuronów (min)
True label
Predicted label
25
1
0
34

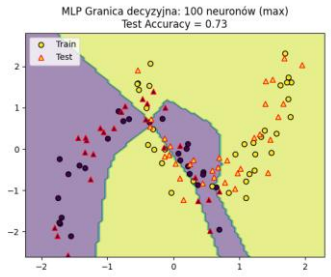

MLP Macierz pomyłek: 5 neuronów (best)
True label
Predicted label
25
1
0
34

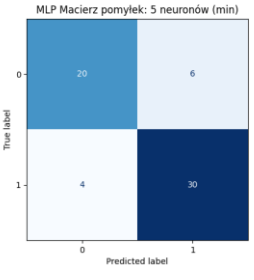

MLP Macierz pomyłek: 100 neuronów (max)
True label
Predicted label
25
1
0
34

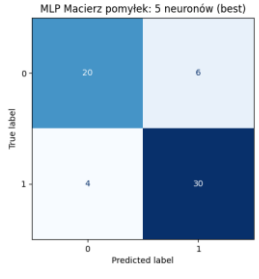

Zmiana Accuracy MLP - 2_3.csv
Accuracy
Liczba neuronów w warstwie ukrytej
Accuracy Treningowe
Accuracy Testowe

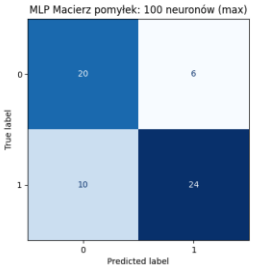

MLP Granica decyzyjna: 5 neuronów (min)
Test Accuracy = 0.83
Train
Test

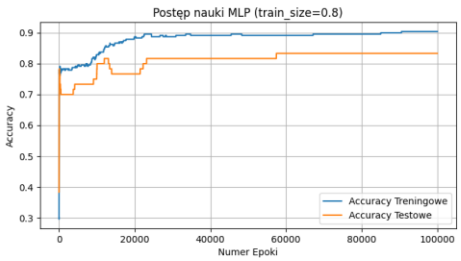

MLP Granica decyzyjna: 5 neuronów (best)
Test Accuracy = 0.83
Train
Test

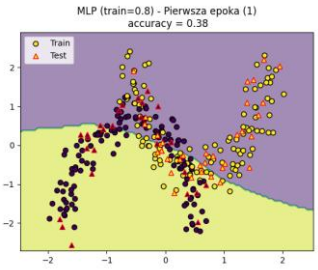

MLP Granica decyzyjna: 100 neuronów (max)
Test Accuracy = 0.73
Train
Test

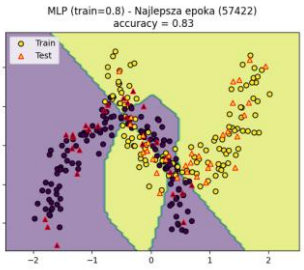

MLP Macierz pomyłek: 5 neuronów (min)
True label
Predicted label
20
6
4
30

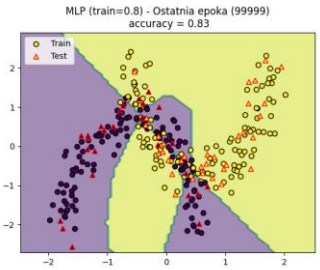

MLP Macierz pomyłek: 5 neuronów (best)
True label
Predicted label
20
6
4
30


MLP Macierz pomyłek: 100 neuronów (max)
True label
Predicted label
20
6
10
24

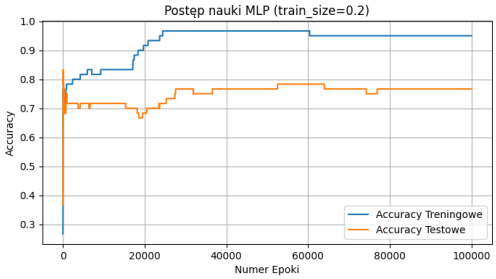


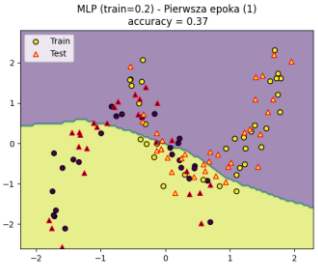


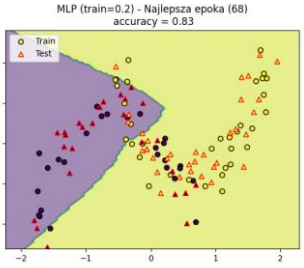


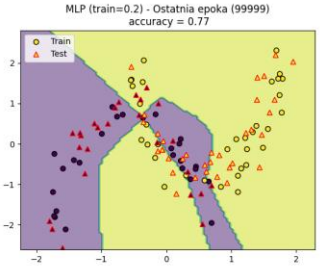


	start(train)	start(test)	best(epoka)	best(train)	best(test)	end (train)	end(test)
1	0.46	0.65	13908	0.80	0.83	0.90	0.83
2	0.47	0.53	62021	0.88	0.85	0.89	0.83
3	0.35	0.45	68409	0.88	0.80	0.88	0.80
4	0.48	0.57	23866	0.88	0.83	0.90	0.83
5	0.28	0.48	23866	0.88	0.83	0.90	0.83
6	0.60	0.65	39618	0.87	0.85	0.88	0.82
7	0.48	0.57	39	0.76	0.82	0.90	0.78
8	0.49	0.45	20004	0.83	0.82	0.90	0.80
9	0.52	0.43	50586	0.92	0.85	0.91	0.83
10	0.29	0.35	47320	0.89	0.83	0.92	0.83









	start(train)	start(test)	best(epoka)	best(train)	best(test)	end (train)	end(test)
1	0.53	0.65	77	0.78	0.80	0.95	0.73
2	0.53	0.53	41704	0.95	0.78	0.95	0.73
3	0.32	0.45	86	0.65	0.85	0.95	0.75
4	0.57	0.57	82	0.72	0.77	0.95	0.73
5	0.25	0.48	213	0.72	0.78	0.95	0.73
6	0.68	0.65	42614	0.95	0.78	0.95	0.73
7	0.57	0.57	338	0.72	0.78	0.95	0.73
8	0.55	0.45	187	0.72	0.78	0.95	0.73
9	0.43	0.43	43071	0.95	0.78	0.95	0.73
10	0.25	0.35	144	0.75	0.78	0.95	0.77

Wpływ hiperparametrów na elastyczność i granice decyzyjnych

Eksperymenty potwierdziły, że dobór hiperparametrów bezpośrednio steruje balansem między niedouczeniem(underfitting) a przeuczeniem(overfitting).

- SVM – jądro *linear* jest niewystarczające dla nieliniowych struktur danych (zbiór 2_3), gdzie zmiana na *rbf* zwiększyła *accuracy* z 0.77 do 0.89. Parametr C decyduje o tym, jak bardzo model 'nie lubi' popełniać błędów na danych treningowych. Jego wzrost zwiększa karę za błędy klasyfikacji, co prowadzi do silniejszego dopasowania modelu do danych treningowych, co zwiększa złożoność granicy i prowadzi do przeuczenia. Optymalną generalizację uzyskano dla średnich wartości *C* (około 2), co potwierdzają eksperymenty dla zbioru 2_3 na stronie 3 (eksperyment 2).
- MLP – Funkcja aktywacji *relu* wprowadza nieliniowość, umożliwiając modelowanie złożonych, nieliniowych granic decyzyjnych, przy funkcji identity sieć neuronowa redukuje się do modelu liniowego, potwierdza to znaczący wzrost miary *accuracy* dla danych 2_3. (eksperyment 1 – strona 7). Zwiększanie liczby neuronów (strona 10) zwiększa elastyczność granicy decyzyjnej. (eksperyment 2)
- KNN – Zbyt niska wartość najbliższych sąsiadów (*k*= 1) prowadzi do przeuczenia modelu. Zwiększanie *k* wygładza granice, poprawiając generalizację, jednak zbyt wysokie wartości prowadzą do utraty istotnych szczegółów podziału (spadek dokładności na obu zbiorach).

Liczebność zbioru treningowego a stabilność modelu

Redukcja danych treningowych z 80% do 20% drastycznie obniża stabilność wszystkich klasyfikatorów:

- SVM – Na wizualizacjach granic decyzyjnych widać, że granica decyzyjna ulega znacznemu przesunięciu, co prowadzi do błędnej klasyfikacji części przestrzeni należącej do przeciwnej klasy. Skutkuje to spadkiem *accuracy* na zbiorze testowym w stosunku do eksperymentu na pełnym zbiorze.
- MLP – Zmniejszenie liczebności danych treningowych przyczyniło się do przeuczenia modelu, co wynika z niedostatecznej liczby przykładów do poprawnego odwzorowania rozkładu danych (strona 13 – wyniki dla danych 2_3)
- KNN – Granice stały się nieregularne, a *accuracy* testowe spadło o nawet 10 punktów procentowych.
- Mały zbiór danych uniemożliwia poprawną ocenę rozkładu klas, co faworyzuje overfitting kosztem zdolności uogólniających.

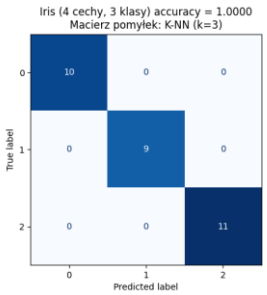
Dynamika procesu uczenia i inicjalizacja wag

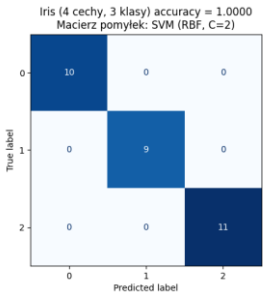
Analiza iteracyjna (epoki) oraz wielokrotne uruchomienia modelu MLP wykazały:

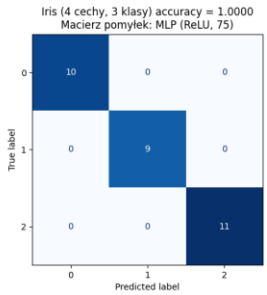
- Na początku działania modelu MLP granica decyzyjna ma charakter przypadkowy. Dopiero w kolejnych epokach sieć zdobywa optymalną zdolność generalizacyjną, co najczęściej następuje w początkowej lub środkowej fazie treningu.
- Optymalny model nie jest produktem najdłuższego możliwego czasu nauki, lecz wynikiem jej zatrzymania w momencie uzyskania najwyższej skuteczności na danych testowych. Dalszy trening prowadzi jedynie do zapamiętywania szumu.
- Uruchamianie procesu nauczania z różnymi wagami początkowymi udowodniło, że uzyskiwane wyniki są różne, czyli model nie jest w pełni powtarzalny. Wahania *accuracy* dla danych testowych sięgają w tym eksperymencie 7 punktów procentowych, co potwierdza potrzebę wielokrotnej weryfikacji modeli neuronowych.

Iris

Klasyfikator	Accuracy	Precision	Recall	F1-Score
KNN	1.00	1.00	1.00	1.00
SVM	1.00	1.00	1.00	1.00
MLP	1.00	1.00	1.00	1.00

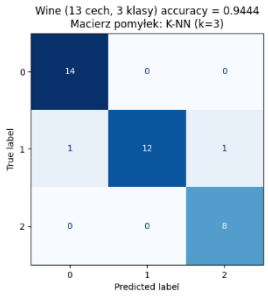


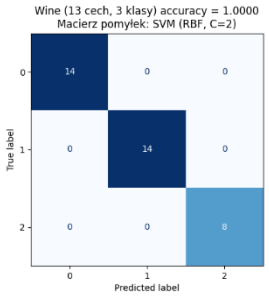


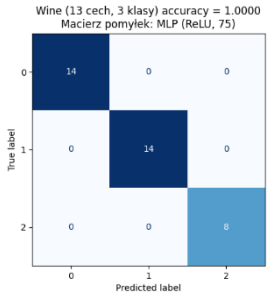


Wine

Klasyfikator	Accuracy	Precision	Recall	F1-Score
KNN	0.94	0.94	0.95	0.94
SVM	1.00	1.00	1.00	1.00
MLP	1.00	1.00	1.00	1.00







Przeprowadzone eksperymenty na zbiorach Iris oraz Wine potwierdzają wcześniejsze wnioski dotyczące wpływu hiperparametrów na zdolność uogólniania modeli. Dobór parametrów (k=3 dla KNN, liczba neuronów = 75 dla MLP oraz C=2 dla SVM) pozwolił uzyskać bardzo wysoką skuteczność klasyfikacji, co wskazuje na trafne dobranie poziomu elastyczności modeli.

Dla zbioru Iris wszystkie klasyfikatory osiągnęły idealnie wyniki (*accuracy* = 1.00). Oznacza to, że dane są dobrze separowalne, a problem klasyfikacji jest stosunkowo prosty.

Zestawienie wyników na zbiorze Wine (13 wymiarów) wskazuje na pewne ograniczenia algorytmu K-Najbliższych Sąsiadów. O ile na prostszej, 4-wymiarowej przestrzeni Iris model KNN (k=3) osiągnął skuteczność 100%, o tyle w 13-wymiarowej przestrzeni Wine jego accuracy spadło do 94.44%. Może to wynikać z faktu, że algorytmy oparte na metryce euklidesowej tracą skuteczność wraz ze wzrostem liczby wymiarów. W przestrzeniach wysokowymiarowych różnice między odległościami maleją, a mniej istotne lub zaszumione cechy zakłócają pojęcie „najbliższego sąsiada”.

Modele uczące się wag (MLP) lub optymalnych granic decyzyjnych (SVM) radzą sobie w takich warunkach lepiej, ponieważ nie opierają się bezpośrednio na surowych odległościach, lecz dopasowują strukturę modelu do danych.