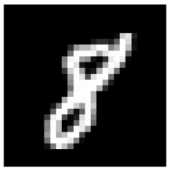
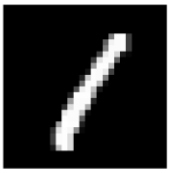
Przeprowadzenie eksperymentu pierwszego wymagało przeprowadzenia ekstrakcji cech ze zbioru MNIST, obrazów o rozmiarze 28 x 28 pikseli, przedstawiających ręcznie pisane cyfry. Przeprowadzenie tego procesu wymagało takiego doboru cech, aby dobrze reprezentowały one kluczowe informacje o kształcie cyfr. Jedna z metod ekstrakcji cech zakładała przygotowanie wektora z dwoma elementami, w ramach tego zaproponowano następujący zestaw cech:

1. **Suma aktywnych pikseli** - reprezentuje całkowitą ilość atramentu użytą do zapisu cyfry. Obliczana jako suma znormalizowanych wartości jasności wszystkich pikseli obrazu. Pozwala na skuteczne odseparowanie cyfr „mniejszych" od „większych".
   Zastosowanie wspomnianej cech można przedstawić na podstawie odróżnienia „1" od „8". Cyfra „1" charakteryzuje się bardzo niską wartością sumy aktywnych pikseli, podczas gdy cyfra „8" posiada wysoką tę wartość. Wybór tej cechy jest intuicyjny, ponieważ cyfry różnią się bardzo od siebie w kwestii potrzebnego atramentu do ich zapisania.

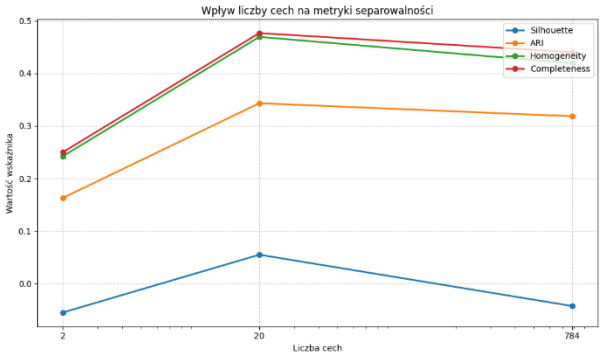



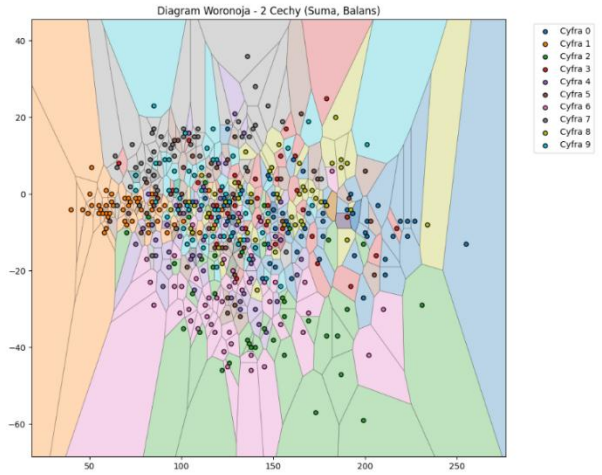
   Dla powyżej przedstawionych cyfr uzyskano następujące wyniki dla sumy aktywnych pikseli:
   - „8" = 133
   - „1" = 82
2. **Różnica liczby aktywnych pikseli pomiędzy górną i dolną częścią obrazu (balans pionowy pikseli)** – cecha opisuje pionowy rozkład pikseli należących do cyfry. Obliczana jest jako różnica liczby aktywnych pikseli w górnej połowie obrazu i liczby aktywnych pikseli w dolnej połowie obrazu.
   Rozróżnienie cyfr „6" oraz „9" w przypadku cechy opisanej poprzez sumę aktywnych pikseli jest prawie niemożliwe, ponieważ obie cyfry mogą posiadać zbliżoną liczbę aktywnych pikseli. Jednak dla cyfry „6" większa część pikseli znajduje się w dolnej części obrazu, co skutkuje ujemną wartością balansu. W przypadku cyfry „9" więcej pikseli znajduje się w górnej części cyfry, dlatego wartość balansu jest wyższa. Cecha ta pozwala więc lepiej opisać pionowe rozmieszczenie elementów znaku i skuteczniej rozróżniać cyfry o podobnej liczbie aktywnych pikseli.




   Dla powyższych cyfr uzyskano następujące wyniki

Cyfra	Suma aktywnych pikseli	Średnia pozycja aktywnych pikseli w osi Y
„6"	97	-31
„9"	103	19





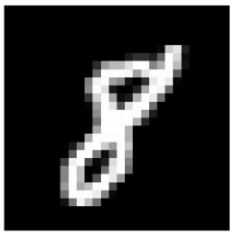
Ilość cech	Silhouette Score	ARI	Homogeneity	Completeness
2	-0.0551	0.1630	0.2422	0.2500
20	0.0548	0.3432	0.4693	0.4767
784	-0.0429	0.3183	0.4190	0.4402

Eksperyment został przeprowadzony na postawie sposobu oceny separowalności w projekcie nr.1, czyli za pomocą algorytmu KMeans, który dowodzi, że jakość separowalności klas silnie zależy od zastosowanej metody ekstrakcji cech. We wszystkich rozpatrywanych przypadkach klastry wyznaczane przez KMeans wykazują silne nakładanie, na co wskazują wartości wskaźnika Silhouette oscylujące wokół zera (a niekiedy przyjmujące wartości ujemne). Analiza pozostałych metryk wykazuje, że zdecydowanie najgorsze wyniki uzyskano dla reprezentacji wykorzystującej zaledwie dwie cechy.

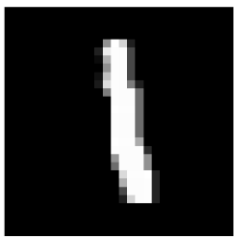
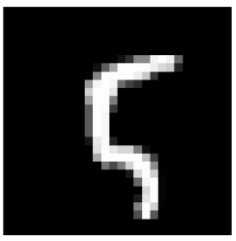
Wizualnym potwierdzeniem tego stanu rzeczy jest diagram Woronoja. Można z niego odczytać jedynie nieliczne, lepiej odseparowane klasy – m.in. cyfrę „1” (ze względu na sumarycznie małą ilość pikseli) oraz „6” (wyróżniającą się ujemnym balansem pionowym pikseli). Zbyt prosta przestrzeń cech prowadzi ponadto do częstego mylenia cyfr o zbliżonej topologii, takich jak „3” oraz „8”. Należy jednak zaznaczyć, że w celu zachowania czytelności wykresu zaprezentowano na nim losową próbkę 500 obiektów, co może nieznacznie rzutować na ogólną ocenę wizualną.

Zastosowanie analizy głównych składowych (PCA) i redukcja do 20 cech znacząco poprawiły jakość reprezentacji danych, co odzwierciedlają wyraźnie wyższe wyniki miar ARI, Homogeneity oraz Completeness. Bardzo zbliżone rezultaty uzyskano dla wektora składającego się z aż 784 cech. Wynik ten sugeruje, że wysoka wymiarowość i obecność niepotrzebnych informacji mogą utrudniać skuteczne grupowanie danych metodami opartymi na odległości euklidesowej, takimi jak KMeans.

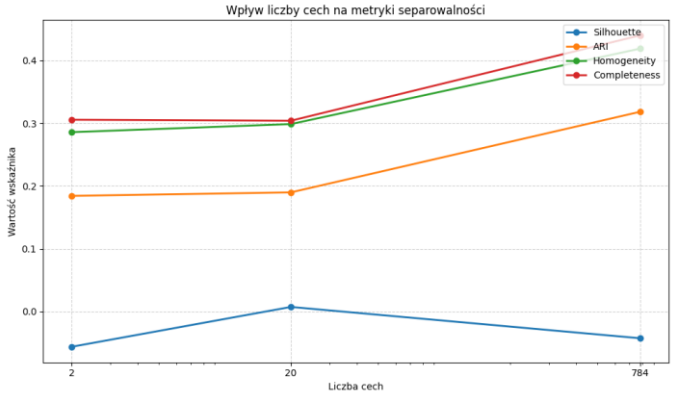
1. **Liczba pętli (liczba zamkniętych obszarów)** – Cecha ta opiera się na analizie topologicznej obrazu i polega na zliczeniu odizolowanych fragmentów tła, które są w całości otoczone przez aktywne piksele (tzw. dziury lub pętle). Jest to cecha, która nie zależy od grubości linii ani wielkości samej cyfry, a jedynie od jej fundamentalnego kształtu.
   Zastosowanie tej cechy można najlepiej przedstawić na przykładzie odróżnienia cyfry „8" od cyfry „3". Cyfra „8" w swojej standardowej formie posiada dwie zamknięte pętle (górną i dolną). Z kolei cyfra „3" jest strukturą otwartą, co oznacza, że liczba pętli w jej przypadku wynosi zero. Wybór tej cechy pozwala na błyskawiczne przypisanie badanej cyfry do jednej z trzech grup: bez pętli (np. 1, 2, 3, 5, 7), z jedną pętlą (0, 6, 9) oraz z dwiema pętlami (8).

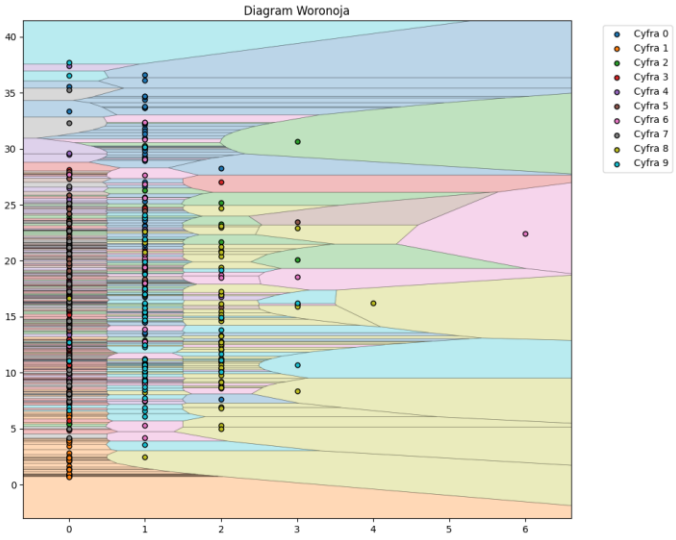



2. **Wariancja pozioma (Szerokość statystyczna)** – cecha mierząca stopień rozproszenia aktywnych pikseli względem pionowej osi symetrii znaku. W procesie ekstrakcji pozwala ona na matematyczne zdefiniowanie „smukłości" cyfry, co jest kluczowe w przypadku znaków o identycznej strukturze topologicznej.
   Cecha ta jest kluczowym uzupełnieniem informacji o liczbie pętli, szczególnie w przypadku cyfr o strukturze otwartej. Rozróżnienie cyfry **„1"** od cyfry **„2"** lub **„5"** jest niemożliwe przy badaniu samej liczby pętli, ponieważ każda z nich posiada ich zero. Jednak cyfra „1" charakteryzuje się skrajnie niską wartością wariancji poziomej, gdyż jej piksele są skupione w wąskim pasie. Cyfry „2" i „5" posiadają szerokie elementy poziome, co skutkuje znacznie wyższą wartością wariancji. Wybór tej cechy pozwala więc skutecznie odróżnić wąskie znaki od szerokich wewnątrz grup o tej samej charakterystyce topologicznej.

   Dla powyżej przedstawionych cyfr uzyskano następujące wyniki dla wariacji poziomej:
   - „1" = 1.95
   - „5" = 8.42





Ilość cech	Silhouette Score	ARI	Homogeneity	Completeness
2	-0.0565	0.1842	0.2857	0.3056
6	0.0071	0. 1897	0.2986	0.2798
784	-0.0429	0.3183	0.4190	0.4402

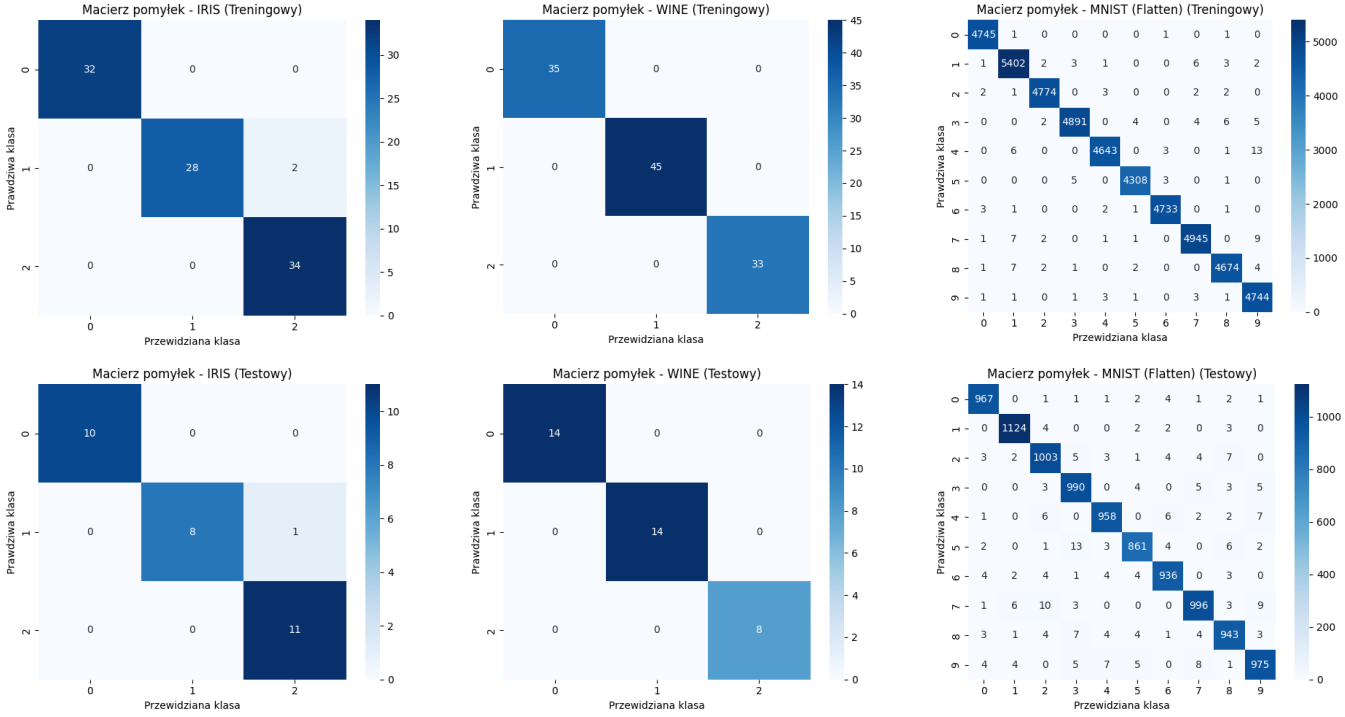
Przeprowadzony eksperyment pokazuje, że jakość separacji klas silnie zależy od metody ekstrakcji cech, a zwiększanie liczby wymiarów nie zawsze poprawia wyniki. We wszystkich przypadkach klastry wyraźnie się nakładają, co potwierdzają wartości wskaźnika Silhouette oscylujące wokół zera. Najsłabszą separację w ujęciu klasteryzacji KMeans uzyskano dla reprezentacji opartej na dwóch oraz sześciu cechach. Potwierdza to diagram Woronoja, gdzie widać efekt dyskretności liczby pętli – cecha ta dzieli przestrzeń na wąskie pionowe pasy, w których punkty silnie się mieszają, co prowadzi do mylenia cyfr o podobnej topologii, np. „4” i „5”. Dodatkowo algorytm wrażliwy jest na niewyraźne cyfry, co może skutkować rozpoznaniem trzech lub więcej dziur w cyfrach, co jest sytuacją zdecydowanie błędną.

Rozszerzenie wektora do sześciu cech intuicyjnych (m.in. symetria i cechy ze strony nr 1) nie przyniosło oczekiwanej poprawy jakości klasteryzacji K-Means, co pokazuje nadal bardzo niski wskaźnik ARI (0.1897 względem 0.1842 dla dwóch cech). Wynika to z dużej wrażliwości cech ręcznie projektowanych na styl pisma – grubość linii czy pochylenie znaku. W efekcie algorytm grupował obiekty według podobieństwa stylistycznego, a nie przynależności do klasy, co skutkowało częstym myleniem np. „3” i „4”. Pokazuje to, że intuicyjne cechy geometryczne bez odpowiedniej selekcji mogą nie wnosić wartościowej wariancji dla metod opartych na odległościach.

Wybór najlepszej architektury dla zbiorów danych Iris, Wine oraz różnych wariantów zbioru MNIST opiera się na ujednoliconej, trzyetapowej strategii selekcji. System ten został zaprojektowany tak, aby obiektywnie wyłonić model o najwyższej zdolności do generalizacji, oddzielając proces treningu od procesu ewaluacji.

1. **Selekcja na poziomie epoki**
   Pierwszy etap odbywa się wewnątrz pętli treningowej dla każdej testowanej konfiguracji hiperparametrów. Zamiast przyjmować stan sieci z ostatniej epoki, algorytm monitoruje funkcję straty (CrossEntropyLoss) na wydzielonym zbiorze walidacyjnym:
   - Zapisywanie najlepszego stanu: Podczas każdej epoki obliczana jest średnia strata walidacyjna. Jeśli w danej epoce model osiągnie najniższy dotychczasowy błąd, jego wagi są zapisywane.
   - Mechanizm Early Stopping: Aby zapobiec przeuczeniu, proces uczenia jest przerywany, jeśli strata walidacyjna nie ulegnie poprawie przez 5 kolejnych epok. Po zakończeniu treningu model automatycznie przywraca parametry z epoki, w której strata była najniższa.
2. **Selekcja na poziomie hiperparametrów**
   Po wytrenowaniu zestawu modeli o różnych parametrach, następuje ich porównanie w celu wyłonienia zwycięzcy dla danego zbioru danych. Na tym etapie kryterium wyboru ulega zmianie:
   - Kryterium Accuracy: Modele są zestawiane na podstawie najwyższej skuteczności osiągniętej na zbiorze walidacyjnym
   - Przestrzeń poszukiwań: Testowane są różne kombinacje rozmiaru warstwy ukrytej (8, 16, 32, 64, 100) oraz zastosowanie funkcji aktywacji (ReLu).
   - Dopasowanie pojemności sieci: Kluczowym elementem jest dobór liczby neuronów do wymiarowości wejścia. Zbyt mała warstwa ukryta dla wysokowymiarowych danych (np. MNIST 784) mogłaby prowadzić do niedouczenia, natomiast zbyt duża dla danych 2-wymiarowych zwiększa ryzyko zapamiętywania szumu. Powyższe podejście jest bezpośrednią odpowiedzią na wnioski wyciągnięte podczas realizacji pierwszego projektu. Zauważono w nim klasyczny dla uczenia maszynowego problem: spadek błędu treningowego nie jest tożsamy ze wzrostem zdolności generalizujących.
3. **Ostateczna weryfikacja na zbiorze testowym**
   Zwieńczeniem procesu jest ocena wyłonionego modelu na całkowicie niezależnym zbiorze testowym. Zbiór ten nie brał udziału ani w aktualizacji wag, ani w wyborze najlepszej konfiguracji hiperparametrów. Wynik uzyskany na tych danych jest jedynym wiarygodnym wskaźnikiem tego, jak sieć poradzi sobie z nowymi, nieznanymi wcześniej obiektami, co stanowi ostateczny dowód na skuteczność walki z zjawiskiem przeuczenia.

Zbiór danych	Accuracy treningowe	Accuracy testowe	Epoka
Iris	0.9792	0.9667	570
Wine	1.0000	1.0000	303
MNIST (784 cechy)	0.9971	0.9753	25



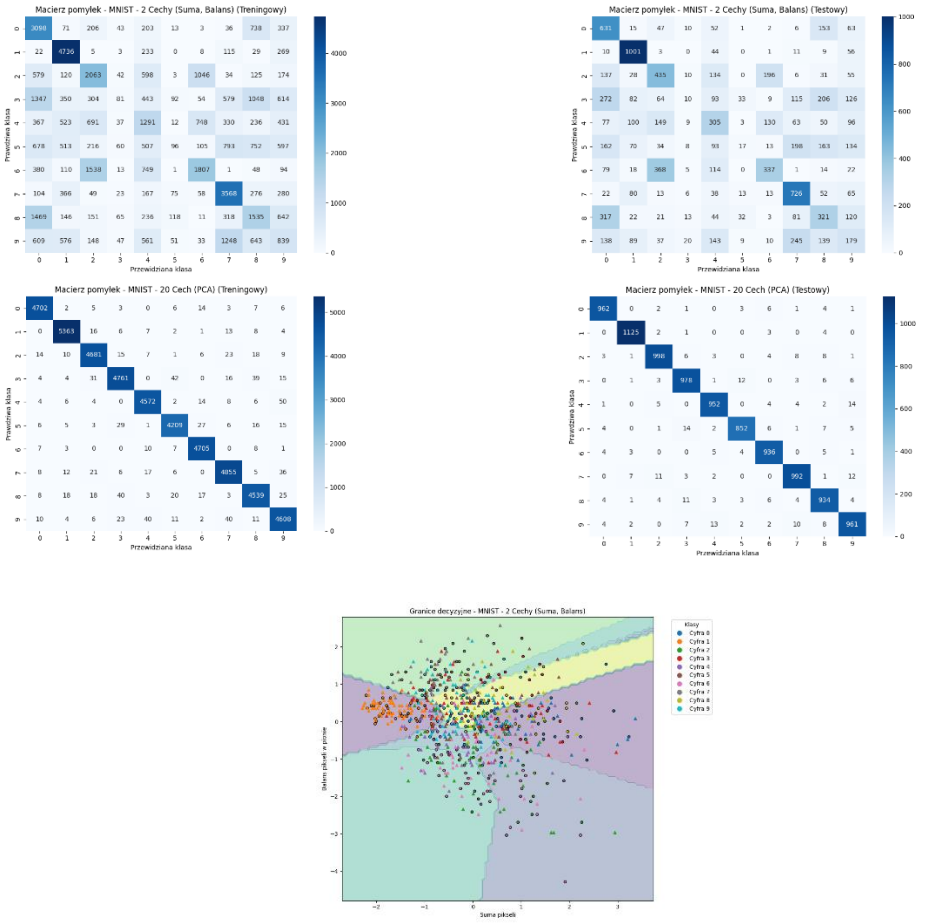
Każdy z optymalnych modeli wykorzystuje funkcję aktywacji ReLu.

Zbiór Iris – optymalny model posiada 16 neuronów w warstwie ukrytej oraz 3 neurony na wyjściu, które odpowiadają trzem klasom Irysów. Warstwa wejściowa modelu przyjmuje 4 neurony, które odpowiadają wymiarowości przestrzeni cech. Model osiągnął skuteczność 97.92% na zbiorze treningowym i 96.67% na zbiorze testowym. Tak mała różnica między tymi wartościami świadczy o znakomitych zdolnościach generalizacyjnych. Model potrzebował 570 epok, aby osiągnąć optymalne wagi. Ten stosunkowo długi czas treningu (w porównaniu do pozostałych zbiorów) wynika najprawdopodobniej z natury zbioru Iris, gdzie dwie klasy (Versicolor i Virginica) silnie na siebie nachodzą w przestrzeni cech.

Zbiór Wine - optymalny model posiada zaledwie 8 neuronów w warstwie ukrytej oraz 3 neurony na wyjściu, które odpowiadają trzem klasom win. Warstwa wejściowa modelu przyjmuje 13 neurony, które odpowiadają wymiarowości przestrzeni cech. Osiągnięto 100% skuteczności zarówno na zbiorze treningowym, jak i testowym, a optymalizacja zakończyła się w 303 epoce.

Zbiór MNIST (784 cechy) - Optymalny model jest znacznie bardziej pojemny – posiada 100 neuronów w warstwie ukrytej oraz 10 neuronów na wyjściu (odpowiadających cyfrom 0-9). Warstwa wejściowa modelu przyjmuje 784 neurony, które odpowiadają wymiarowości przestrzeni cech. Trening został zatrzymany już w 25 epoce. Model Flatten dla obrazków 28x28 przyjmuje aż 784 cechy wejściowe, co przy 100 neuronach w warstwie ukrytej daje sieć o olbrzymiej pojemności. Taka sieć szybko dopasowała się do danych treningowych, niemal idealnie dopasowując się do zbioru uczącego (Train Loss spadł do zaledwie 0.0144). Dodatkowo na podstawie macierzy pomyłek można zauważyć, że model myli cyfry „7” z „2” oraz „5” z „3”, czyli cyfry, które dzielą podobną strukturę pikseli.

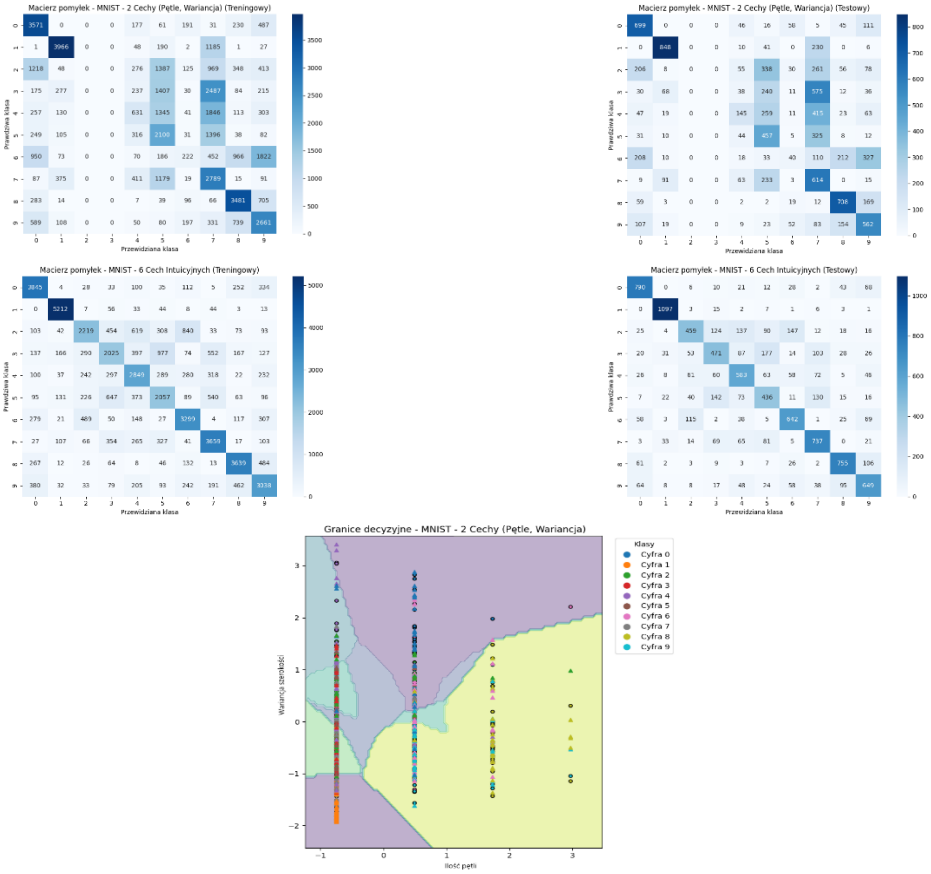
Zbiór danych	Accuracy treningowe	Accuracy testowe	Epoka
2 cechy	0.3982	0.3962	43
20 cech	0.9791	0.9690	75



2 cechy (ilość pikseli i balans pionowy pikseli) - model osiągnął niską skuteczność ~39.6%, co wynika z drastycznego pozbawienia danych kluczowych informacji i bezpośrednio potwierdza brak naturalnej separowalności klas stwierdzony na stronie 2. Przy ujemnym wskaźniku Silhouette (-0.0551) próbki nie tworzą dobrze odseparowanych klastrów, przez co sieć nie jest w stanie wytyczyć sensownych granic, co skutkuje przypadkowymi i nieregularnymi podziałami tła na wykresie. Jedynym jasnym punktem jest relatywnie poprawna klasyfikacja cyfry "1", co potwierdza wykres granic decyzyjnych, gdzie pomarańczowe trójkąty grupują się z lewej strony ze względu na najniższą sumę pikseli („zużycie atramentu").

20 cech - zastosowanie algorytmu PCA do ekstrakcji 20 składowych przyniosło bardzo dobre rezultaty (96.90% na zbiorze testowym), co przy redukcji wymiarów o 97,5% stanowi sukces w porównaniu do modelu opartego na 784 cechach. Ta wysoka skuteczność idealnie koreluje z wyraźnym wzrostem wskaźnika ARI (0.34) oraz miar Homogeneity i Completeness dla tej metody opisanych na stronie 2. Wynik ten sugeruje, że algorytm PCA skutecznie zachował kluczową wariancję danych, tworząc 20-wymiarową przestrzeń o znacznie wyższej separowalności niż w przypadku ręcznie dobranych cech intuicyjnych, co pozwoliło sieci MLP na precyzyjne wyznaczenie granic decyzyjnych.

Zbiór danych	Accuracy treningowe	Accuracy testowe	Epoka
2 cechy	0.4046	0.4073	31
6 cech	0.6634	0.6619	64



2 cechy (ilość pętli, wariacja szerokości) – model osiągnął bardzo niską skuteczność na poziomie ~40.7%, co bezpośrednio odzwierciedla wnioski z analizy separowalności klas. Zastosowanie dyskretnej cechy liczby pętli sprawiło, że na wykresie granic decyzyjnych punkty układają się w gęste, pionowe pasy, w obrębie których klasy silnie się ze sobą mieszają. W tych obszarach sieć neuronowa nie jest w stanie wytyczyć nieliniowych, skutecznych granic, co znajduje idealne odzwierciedlenie w macierzy pomyłek dla zbioru testowego. Pokazuje ona dobitnie, że model ma trudności przy rozróżnianiu cyfr o identycznej topologii – nagminnie myląc ze sobą np. „3”, „4” z „7” (znaki bez pętli), co ostatecznie udowadnia, że ta dwuwymiarowa reprezentacja charakteryzuje się słabą separacją.

6 cech – rozszerzenie wektora do sześciu cech pozwoliło modelowi osiągnąć skuteczność na poziomie ~66.2%. Choć jest to znaczący wzrost w porównaniu do modelu opartego na 2 cechach, w kontekście problemu MNIST jest to wynik nadal niesatysfakcjonujący, który w rzeczywistości potwierdza założenia ze strony 4 o bardzo słabej separowalności tej przestrzeni. Zwiększenie liczby wymiarów dostarczyło sieci neuronowej więcej informacji do nauki, co pozwoliło jej poprawić wynik bazowy, jednak szybko natrafiła ona na barierę wynikającą z ograniczeń samych cech. Z powodu wrażliwości ręcznie projektowanych cech na indywidualny styl pisma, klastry wciąż na siebie nachodzą, przez co model masowo myli cyfry o podobnej strukturze wizualnej. Potwierdza to macierz pomyłek na zbiorze testowym, gdzie wyraźnie widać częste mylenie m.in. cyfry „3” z „5” oraz „2” z „4”.