Analiza wyjaśnialności sieci neuronowych

Jan Śladowski
Politechnika Łódzka
264403@edu.p.lodz.pl

Dominik Gałkowski
Politechnika Łódzka
264312@edu.p.lodz.pl

***Abstract*—Sztuczne sieci neuronowe, pomimo wysokiej skuteczności w rozwiązywaniu złożonych problemów, charakteryzują się naturą tzw. czarnej skrzynki (ang. black box), co utrudnia ich wdrażanie w obszarach krytycznych wymagających przejrzystości procesu decyzyjnego. Niniejszy artykuł prezentuje analizę działania modeli neuronowych o zróżnicowanej architekturze (MLP oraz CNN) wytrenowanych na zbiorach danych tabelarycznych (Iris, Wine) oraz wizyjnych (MNIST, Imagenette). W celu zrozumienia logiki wnioskowania sieci zastosowano techniki objaśnialnej sztucznej inteligencji (XAI), w tym metody oparte na gradientach (Saliency, Integrated Gradients) oraz aproksymacje lokalnymi modelami zastępczymi (LIME). Analizę przeprowadzono z wykorzystaniem biblioteki Captum, skupiając się na podejściu lokalnym – wyznaczaniu wartości atrybucji poszczególnych cech wejściowych oraz interpretowalnych komponentów (super-pikseli algorytmu SLIC dla obrazów). Przeprowadzone eksperymenty wykazują skuteczność wybranych metod w identyfikacji kluczowych atrybutów determinujących predykcje (np. dominujący wpływ zawartości alkoholu i proliny w klasyfikacji win). Co istotne, uzyskane mapy atrybucji dla błędnych klasyfikacji pozwoliły skutecznie zdiagnozować słabości modeli, uwidaczniając zjawisko faworyzowania cech tła nad właściwymi cechami obiektu. Wyniki potwierdzają, że lokalne metody objaśniające są kluczowym narzędziem do walidacji, wykrywania anomalii oraz budowania zaufania do modeli uczenia maszynowego.**

I. Wprowadzenie

Dynamiczny rozwój algorytmów uczenia maszynowego, w szczególności sztucznych sieci neuronowych, przyniósł bezprecedensowy wzrost skuteczności w rozwiązywaniu złożonych problemów klasyfikacyjnych, takich jak analiza obrazów, przetwarzanie języka naturalnego czy diagnostyka medyczna. Pomimo wysokiej dokładności predykcyjnej, modele oparte na uczeniu głębokim charakteryzują się naturą tzw. "czarnej skrzynki" (ang. black box). Ich wielowarstwowa architektura sprawia, że wewnętrzny proces decyzyjny jest niezrozumiały dla człowieka. Stanowi to krytyczną barierę we wdrażaniu tych technologii w systemach o wysokim ryzyku (np. medycyna), gdzie transparentność i możliwość weryfikacji logiki modelu są równie ważne co jego dokładność. Odpowiedzią na ten problem jest dziedzina objaśnialnej sztucznej inteligencji (XAI, ang. Explainable Artificial Intelligence), która dostarcza narzędzi pozwalających na zrozumienie oraz ocenę zachowania modeli predykcyjnych.

Formalnie, problem klasyfikacji można zdefiniować jako funkcję mapującą $F : \mathbb{R}^n \to \mathbb{R}^C$, która reprezentuje wytrenowany model neuronowy. Niech $x \in \mathbb{R}^n$ oznacza wektor wejściowy (pojedynczą obserwację), taki że $x = [x_1, x_2, \ldots, x_n]$, gdzie n to całkowita liczba cech wejściowych (np. atrybutów tabelarycznych lub pikseli obrazu). Przestrzeń wyjściowa $\mathbb{R}^C$ odpowiada liczbie klas C, a wyjście modelu $y = F(x)$ reprezentuje wektor prawdopodobieństw przynależności obserwacji x do każdej z klas. Predykcja końcowa modelu to najczęściej klasa c o największym prawdopodobieństwie, tj. $c = \arg\max_{j \in \{1,\ldots,C\}} y_j$.

Głównym zadaniem metod XAI w ujęciu lokalnym jest przypisanie każdej cesze wejściowej x_i wartości liczbowej określającej jej wpływ na ostateczną decyzję modelu względem wybranej klasy c. Proces ten definiuje się jako znalezienie wektora atrybucji $A^c(x) \in \mathbb{R}^n$, który przyjmuje postać:

$$A^c(x) = [a_1, a_2, \ldots, a_n] \tag{1}$$

gdzie skalar $a_i \in \mathbb{R}$ określa ważność (atrybucję) i-tej cechy. Znak wartości a_i ma kluczowe znaczenie interpretacyjne:

- $a_i > 0$ oznacza, że obecność danej cechy pozytywnie wpływa na pewność modelu co do wyboru klasy c (cecha wspierająca),
- $a_i < 0$ wskazuje, że cecha ta zmniejsza prawdopodobieństwo wyboru klasy c (cecha negująca),
- $a_i \approx 0$ sugeruje, że cecha jest obojętna dla rozpatrywanej predykcji.

W zależności od skomplikowania zbioru wejściowego, wektor x może składać się z zaledwie kilku wartości liczbowych (np. wymiary kwiatów lub parametry chemiczne wina), jak i tysięcy pikseli (w przypadku analizy obrazów). Dla danych o wysokiej wymiarowości stosuje się często grupowanie cech w tak zwane interpretowalne komponenty, co pozwala na wyznaczanie atrybucji dla spójnych semantycznie fragmentów przestrzeni wejściowej (np. super-pikseli).

Celem niniejszej pracy jest ewaluacja lokalnych metod wyznaczania wektora $A^c(x)$ dla zróżnicowanych architektur sieci neuronowych (wielowarstwowych perceptronów MLP oraz konwolucyjnych sieci CNN) wdrożonych w ekosystemie PyTorch. Badania przeprowadzono na czterech zbiorach danych: Iris, Wine, MNIST oraz Imagenette. Analiza ta ma na celu zweryfikowanie spójności predykcji modelu z ludzką intuicją, ocenę na jakiej podstawie model podejmuje decyzje oraz diagnostykę potencjalnych błędów klasyfikatora wynikających z faworyzowania cech szumu lub tła.

II. Powiązane prace

Problem interpretowalności i objaśnialności modeli uczenia maszynowego zaowocował w ostatnich latach powstaniem szeregu różnorodnych podejść algorytmicznych. Metody te można ogólnie podzielić na kategorie agnostyczne (niezależne

od architektury modelu) oraz metody bazujące na specyfice danej architektury (np. wykorzystujące gradienty w sieciach neuronowych).

A. Metoda LIME (Local Interpretable Model-agnostic Explanations)

Wśród metod agnostycznych, jednym z najpopularniejszych algorytmów jest LIME, zaproponowany przez Ribeiro i in. [1]. Działanie tej metody polega na uczeniu prostego, w pełni interpretowalnego modelu zastępczego (np. regresji liniowej) na generowanych lokalnie, zaburzonych próbkach w bliskim otoczeniu analizowanej predykcji. W przypadku danych o wysokiej wymiarowości, takich jak obrazy, LIME pozwala na identyfikację obszarów wejścia (nazywanych interpretowalnymi komponentami lub super-pikselami), które miały decydujący wpływ na wynik klasyfikatora, oferując wysoce intuicyjne dla człowieka wizualizacje.

Kluczową zaletą tego podejścia jest jego uniwersalność – traktując wyjaśniany algorytm jako „czarną skrzynkę", LIME umożliwia interpretację dowolnego modelu klasyfikacji lub regresji, niezależnie od stopnia złożoności jego architektury. Twórcy metody kładą przy tym szczególny nacisk na tzw. lokalną wierność , co oznacza, że model zastępczy musi precyzyjnie odzwierciedlać zachowanie systemu w bliskim otoczeniu badanej próbki, nawet jeśli globalna funkcja decyzyjna jest silnie nieliniowa. Konstrukcja ta opiera się na ścisłym kompromisie matematycznym pomiędzy wiernością aproksymacji a złożonością samego objaśnienia, która ze względu na ludzkie ograniczenia poznawcze musi pozostać na tyle niska, by była łatwo zrozumiała dla człowieka.

B. Mapy Istotności (Saliency)

Dla modeli opartych na głębokich sieciach neuronowych popularnym podejściem jest wykorzystanie propagacji wstecznej, ponieważ pozwala na przypisanie atrybucji w zaledwie jednym przejściu w przód i w tył przez sieć, co czyni obliczenia bardzo szybkimi. Podstawową techniką w tej grupie są mapy Saliency (mapy istotności) [2], polegające na obliczeniu wartości bezwzględnej pochodnej cząstkowej wyjścia modelu względem wektora wejściowego. Podejście to, należące do tzw. metod lokalnych, wskazuje, w jaki sposób nieskończenie mała zmiana wartości danej cechy wpłynie na predykcję.

Choć metoda ta jest z definicji wydajna, bywa bardzo podatna na zaszumienie wizualne. Jak wykazali w swoich analizach Ancona i in., metody oparte na gradientach charakteryzują się wyższą lokalną wariancją, a w przypadku złożonych modeli generują mapy ciepła zanieczyszczone szumem o wysokiej częstotliwości. Ponadto, zastosowanie w klasycznym Saliency wartości bezwzględnej gradientu stwarza dodatkowy problem: uniemożliwia rozróżnienie cech, które wspierają predykcję sieci (dowody pozytywne), od tych, które ją osłabiają (dowody negatywne). Powoduje to, że wyciąganie na ich podstawie jednoznacznych wniosków bywa mocno utrudnione.

C. Zintegrowane Gradienty (Integrated Gradients)

Rozwinięciem i udoskonaleniem klasycznych podejść gradientowych jest metoda Integrated Gradients (IG). Sundararajan i in. [3] wykazali, że wiele klasycznych technik atrybucji nie spełnia rygorystycznych wymogów teoretycznych, łamiąc fundamentalne aksjomaty wrażliwości (ang. Sensitivity) oraz niezmienniczości względem implementacji (ang. Implementation Invariance). Jako rozwiązanie wprowadzili metodę IG, która oblicza atrybucje poprzez całkowanie gradientów wzdłuż interpolowanej ścieżki – od wybranego punktu referencyjnego (ang. baseline, symbolizującego brak informacji wejściowej) do analizowanego wejścia. Podejście to zachowuje pełną spójność teoretyczną, skutecznie ograniczając problemy związane z nasyceniem gradientów w głębokich sieciach neuronowych. Ponadto, metoda ta spełnia kluczowy aksjomat kompletności (ang. Completeness), co oznacza, że suma wyznaczonych atrybucji wszystkich cech wejściowych odpowiada dokładnie różnicy między wynikiem modelu dla analizowanego wejścia a wartością dla punktu odniesienia. Autorzy dowiedli również unikalności teoretycznej swojego rozwiązania, wykazując, że Integrated Gradients jest jedyną metodą ścieżkową zachowującą symetrię (ang. Symmetry-Preserving), czyli traktującą cechy o identycznym znaczeniu dla sieci w dokładnie ten sam sposób. Ze względu na brak konieczności modyfikacji samej architektury modelu oraz prostotę implementacji bazującą na standardowym operatorze gradientu, podejście to znalazło szerokie zastosowanie m.in. w sieciach wizyjnych, przetwarzaniu języka naturalnego oraz modelach chemicznych.

III. Metody

W niniejszej pracy do wyznaczenia wektora atrybucji $A^c(x)$ dla wytrenowanych klasyfikatorów zastosowano trzy zróżnicowane algorytmicznie techniki: Saliency, Integrated Gradients oraz LIME. Wszystkie metody zostały zaimplementowane z wykorzystaniem biblioteki Captum dla modeli stworzonych w ekosystemie PyTorch. Metody te operują na oryginalnej funkcji predykcyjnej F w celu objaśnienia jej zachowania względem konkretnej instancji wejściowej x.

A. Mapy Istotności (Saliency)

Najprostszą z analizowanych technik opartych na propagacji wstecznej są mapy istotności (ang. *Saliency maps*). Metoda ta opiera się na analizie pierwszego rzędu i może być traktowana jako pierwszy człon rozwinięcia w szereg Taylora funkcji realizowanej przez sieć [2]. Wyznacza ona wektor atrybucji poprzez obliczenie wartości bezwzględnej z gradientu (pochodnej cząstkowej) wyniku docelowego neuronu $S_c(x)$ względem wielowymiarowego wektora wejściowego x:

$$A^c(x) = \left| \frac{\partial S_c(x)}{\partial x} \right| \tag{2}$$

Skalar a_i wchodzący w skład wektora $A^c(x)$ odpowiada bezpośrednio za to, które cechy wejściowe x_i (np. intensywności pikseli) wymagają najmniejszej modyfikacji, aby wyjście docelowe zmieniło się w największym stopniu.

Zgodnie z definicją metody, kluczowe jest nałożenie wartości bezwzględnej na pochodną cząstkową. Pozwala to wskazać obszary największej czułości klasyfikatora, jednak jak zauważają Ancona i in. [2], podejście to niesie za sobą poważną wadę interpretacyjną. Użycie modułu uniemożliwia detekcję i rozróżnienie dowodów pozytywnych oraz negatywnych, które mogą być obecne na wejściu sieci. W efekcie algorytm nie jest w stanie wykazać, czy dana cecha stymuluje, czy tłumi aktywację neuronu wyjściowego, co w przypadku bardziej złożonych architektur znacząco utrudnia wyciąganie jednoznacznych wniosków z wygenerowanych map.

B. Zintegrowane Gradienty (Integrated Gradients)

Aby zniwelować problem saturacji gradientów – zjawiska, w którym istotna cecha wejściowa otrzymuje zerowy gradient z powodu nasycenia funkcji aktywacji (np. ReLU) – zastosowano metodę Integrated Gradients (IG) [3]. Metoda ta wymaga zdefiniowania analitycznego punktu referencyjnego (tzw. baseline) $x' \in \mathbb{R}^n$, który reprezentuje dla modelu całkowity brak informacji. Wartość atrybucji a_i dla i-tej cechy obliczana jest jako całka z gradientów wzdłuż prostej ścieżki interpolującej między punktem referencyjnym x' a aktualnym wejściem x:

$$A_i^c(x) = (x_i - x_i') \times \int_{\alpha=0}^{1} \frac{\partial F_c(x' + \alpha(x - x'))}{\partial x_i} d\alpha \qquad (3)$$

Skuteczność tej metody silnie zależy od doboru odpowiedniego x'. W przeprowadzonych eksperymentach, dla zbiorów tabelarycznych (Iris, Wine) jako punkt referencyjny przyjęto uśredniony wektor wartości cech ze zbioru treningowego ($x' = \bar{X}_{train}$). Z kolei dla dziedziny obrazów (MNIST, Imagenette) rolę baseline'u pełnił obraz całkowicie czarny, uzyskany poprzez odpowiednią transformację znormalizowanych tensorów wejściowych. Ponieważ w praktyce wyliczenie ciągłej całki dla sieci neuronowych jest analitycznie trudne, w badaniach zastosowano aproksymację numeryczną z wykorzystaniem sumy Riemanna ze zdefiniowaną liczbą kroków całkowania.

C. LIME (Local Interpretable Model-agnostic Explanations)

Ostatnią z wykorzystanych metod jest agnostyczny algorytm LIME [1]. Metoda ta unika bezpośredniego operowania na propagacji wstecznej sieci F. Zamiast tego algorytm przybliża lokalne zachowanie modelu, generując zaburzone próbki w otoczeniu analizowanego punktu x, a następnie dopasowuje do nich prosty, liniowy model zastępczy g, należący do klasy modeli interpretowalnych G. Wektor atrybucji wynika z rozwiązania poniższego problemu optymalizacyjnego:

$$A^c(x) \approx \arg\min_{g \in G} \mathcal{L}(F, g, \pi_x) + \Omega(g) \qquad (4)$$

gdzie $\mathcal{L}$ jest funkcją straty mierzącą błąd aproksymacji modelu g względem "czarnej skrzynki" F w sąsiedztwie zdefiniowanym przez funkcję odległości (podobieństwa) π_x, a $\Omega(g)$ stanowi czynnik regularyzujący.

W przeprowadzonych analizach model zastępczy g trenowano za pomocą $N = 200$ sztucznie wygenerowanych próbek. Co niezwykle istotne, algorytm nie operuje bezpośrednio na oryginalnych cechach, ponieważ dla obrazów o wysokiej rozdzielczości (takich jak w zbiorze Imagenette) modyfikowanie pojedynczych pikseli nie ma sensu semantycznego. Zamiast tego zredukowano wymiarowość problemu, wykorzystując reprezentację opartą na interpretowalnych komponentach (definiowaną za pomocą parametru feature_mask). Za pomocą algorytmu segmentacji SLIC pogrupowano sąsiadujące piksele o zbliżonej charakterystyce w tzw. super-piksele. Podczas procesu perturbacji te spójne fragmenty były losowo "włączane" lub "wyłączane" (zastępowane wartościami bazowymi). Pozwoliło to uzyskać czytelne objaśnienia operujące na spójnych elementach strukturalnych obrazu.

IV. Wyniki eksperymentów

A. Zbiory danych i specyfikacja modeli

Eksperymenty ewaluacyjne przeprowadzono z wykorzystaniem czterech zróżnicowanych zbiorów danych, co pozwoliło na kompleksową ocenę metod XAI w różnych domenach. Do klasyfikacji danych tabelarycznych wykorzystano zbiór Iris (4 cechy, 3 klasy) oraz Wine (13 cech, 3 klasy), dla których wytrenowano modele wielowarstwowe MLP. W dziedzinie widzenia komputerowego wykorzystano zbiór MNIST (klasyfikacja cyfr 0-9) oraz Imagenette (10 klas obrazów). Dla analizy obrazów wykorzystano głębokie sieci konwolucyjne (CNN), a w celach porównawczych dla zbioru MNIST przetestowano również model MLP działający na zredukowanej przestrzeni dwóch ręcznie wyekstrahowanych cech geometrycznych (liczba pętli oraz wariancja szerokości).

B. Analiza atrybucji dla zbioru Iris

Pierwszym rozważanym zbiorem dla danych tabelarycznych o niskiej wymiarowości był zbiór Iris, składający się z pomiarów trzech gatunków irysów (Setosa, Versicolor, Virginica). Każda obserwacja opisana jest za pomocą czterech cech numerycznych: długości i szerokości działki kielicha (odpowiednio cechy 1 i 2) oraz długości i szerokości płatka (cechy 3 i 4). Do klasyfikacji wykorzystano wytrenowaną sieć neuronową MLP. W Tabelach I-VI zestawiono wyniki działania trzech metod objaśniających (Saliency, Integrated Gradients, LIME) dla wybranych próbek testowych reprezentujących poszczególne klasy. (x_1 – sepal length (cm), x_2 – sepal width (cm), x_3 – petal length (cm), x_4 – petal width (cm))

TABLE I
Wyniki metod XAI dla próbki 1

Prawdziwa klasa	versicolor
Predykcja modelu	versicolor

	x_1	x_2	x_3	x_4
Wartości wejściowe	6.1	2.8	4.7	1.2
Saliency	0.5873	0.6118	1.4860	**2.5023**
Integrated Gradients	**0.2939**	0.2769	-0.0064	-0.0220
LIME	**0.2246**	0.1145	0.0000	-0.0228

TABLE II
WYNIKI METOD XAI DLA PRÓBKI 4

Prawdziwa klasa	versicolor
Predykcja modelu	versicolor

	x_1	x_2	x_3	x_4
Wartości wejściowe	6.0	2.9	4.5	1.5
Saliency	0.5873	0.6118	1.4860	**2.5023**
Integrated Gradients	0.2050	0.1353	-0.0727	**-0.5109**
LIME	0.1710	0.1335	0.0000	**-0.4453**

TABLE III
WYNIKI METOD XAI DLA PRÓBKI 3

Prawdziwa klasa	virginica
Predykcja modelu	virginica

	x_1	x_2	x_3	x_4
Wartości wejściowe	7.7	2.6	6.9	2.3
Saliency	0.2034	0.9634	1.7882	**2.8333**
Integrated Gradients	0.7415	0.8775	3.0798	**4.0950**
LIME	0.6127	0.7890	3.1991	**4.1153**

TABLE IV
WYNIKI METOD XAI DLA PRÓBKI 8

Prawdziwa klasa	virginica
Predykcja modelu	virginica

	x_1	x_2	x_3	x_4
Wartości wejściowe	6.9	3.1	5.1	2.3
Saliency	0.2034	0.9634	1.7882	**2.8333**
Integrated Gradients	0.5320	-0.0642	1.2308	**3.9168**
LIME	0.5539	-0.0351	0.9430	**3.9792**

TABLE V
WYNIKI METOD XAI DLA PRÓBKI 2

Prawdziwa klasa	setosa
Predykcja modelu	setosa

	x_1	x_2	x_3	x_4
Wartości wejściowe	5.7	3.8	1.7	0.3
Saliency	**1.2423**	1.2382	1.2277	0.6976
Integrated Gradients	0.2007	**2.5362**	1.7411	0.9741
LIME	0.1438	**2.4132**	1.6309	0.9525

TABLE VI
WYNIKI METOD XAI DLA PRÓBKI 6

Prawdziwa klasa	setosa
Predykcja modelu	setosa

	x_1	x_2	x_3	x_4
Wartości wejściowe	5.4	3.4	1.5	0.4
Saliency	**1.2423**	1.2382	1.2277	0.6976
Integrated Gradients	0.7667	1.2310	**2.0088**	0.8038
LIME	0.7041	1.1447	**1.8529**	0.7457

Analiza wygenerowanych objaśnień ujawnia istotne różnice w zachowaniu poszczególnych algorytmów XAI, a także pozwala zwalidować logikę decyzyjną samego modelu. Najbardziej uderzającą anomalią jest zachowanie metody Saliency. Jak zaobserwowano podczas eksperymentów, dla próbek wewnątrz tej samej klasy (np. Versicolor), metoda ta generuje identyczny wektor atrybucji (odpowiednio [0.587, 0.612, 1.486, 2.502]), niezależnie od lokalnych wahań wartości wejściowych. Zjawisko to wynika z matematycznej natury samej metody Saliency – w prostych modelach MLP z funkcjami aktywacji takimi jak ReLU, powierzchnia decyzyjna ma charakter odcinkowo-liniowy. Gradient pozostaje stały na dużych obszarach przestrzeni wejściowej, co czyni mapy istotności nieczułymi na subtelne różnice badanych próbek. Stanowi to dowód na teoretyczne ograniczenia metod opartych na czystych pochodnych cząstkowych dla prostych architektur.

W przeciwieństwie do Saliency, metody Integrated Gradients (IG) oraz LIME wykazują wysoką wrażliwość lokalną i są ze sobą wysoce zgodne. Wygenerowane przez nie wektory atrybucji potwierdzają, że model zaadaptował reguły w pełni zgodne z wiedzą dziedzinową. Dla gatunku Virginica, charakteryzującego się największymi rozmiarami kwiatostanu, najwyższe wagi przypisywane są długości i szerokości płatka (cechy 3 i 4). Z kolei w klasyfikacji gatunku Setosa (Próbka 2), obok wymiarów płatka, kluczową rolę wspierającą (wartość 2.41 w metodzie LIME) odgrywa szerokość działki kielicha (cecha 2).

Niezwykle wartościowym spostrzeżeniem jest identyfikacja reguł negujących przy klasyfikacji klasy granicznej – Versicolor (Próbka 4). Posiada ona wymiary pośrednie, co generuje wahanie modelu. Metody IG oraz LIME precyzyjnie ujawniają ten mechanizm, przypisując ujemne atrybucje dla szerokości płatka (odpowiednio -0.51 i -0.45). Oznacza to, że parametr ten był na tyle duży, że obniżał pewność modelu co do klasy Versicolor na rzecz innej klasy. Ostateczna, poprawna predykcja została jednak utrzymana dzięki dominującemu, pozytywnemu wkładowi pozostałych wymiarów. Obserwacja ta dowodzi, że metody XAI skutecznie mapują nie tylko reguły potwierdzające klasyfikację, ale również rozstrzygają o kompromisach decyzyjnych podejmowanych przez sieć neuronową.

C. Analiza atrybucji dla zbioru Wine

Kolejnym etapem ewaluacji była analiza modelu MLP wyszkolonego na zbiorze Wine. Zbiór ten stanowi bardziej złożone środowisko testowe – każda obserwacja opisana jest za pomocą 13 cech, które definiują profil jednego z trzech typów win (class_0, class_1, class_2). Z uwagi na wyższą wymiarowość przestrzeni wejściowej w porównaniu do zbioru Iris, prezentacja pełnych, trzynastoelementowych wektorów atrybucji mogłaby zaburzyć czytelność analizy. Z tego powodu w Tabeli VII zestawiono wartości atrybucji (wyznaczone za pomocą metod Saliency, Integrated Gradients oraz LIME) wyłącznie dla tych cech, które miały kluczowe, dominujące znaczenie decyzyjne w procesie wnioskowania sieci dla wybranych, reprezentatywnych próbek z każdej klasy.

TABLE VII
WARTOŚCI ATRYBUCJI DLA KLUCZOWYCH CECH W ZBIORZE WINE (BOLD = NAJWAŻNIEJSZA CECHA DLA DANEJ METODY)

Próbka (Klasa)	Cecha	Saliency	IG	LIME
Próbka 1	**prol**	**0.8792**	0.4121	0.3839
(*class_0*)	alc	0.8352	**0.8282**	**0.7928**
	flav	0.5366	0.5007	0.5067
	od	0.5365	0.6002	0.6257
	ash	0.3847	0.3376	0.2726
Próbka 2	prol	**0.8329**	1.1766	1.1114
(*class_0*)	alc	0.8184	**1.4479**	**1.3138**
	od	0.8159	0.7720	0.8456
	flav	0.6726	0.3868	0.4272
	ash	0.3748	0.1252	0.0669
Próbka 3	col	**1.1185**	-0.2350	-0.1769
(*class_2*)	hue	0.9833	0.7896	0.7539
	od	0.8650	0.3857	0.3506
	flav	0.7354	**1.3766**	**1.3463**
	mag	0.5798	-0.1786	-0.1338
Próbka 5	prol	**0.7667**	**0.7634**	**0.6936**
(*class_1*)	col	0.7323	0.1137	0.0483
	alc	0.5892	0.6454	0.5689
	mag	0.4208	0.6220	0.5747
	ash	0.2450	0.5601	0.5057
Próbka 7	col	**0.7323**	**1.1467**	**1.1154**
(*class_1*)	alc	0.5892	0.9749	0.9648
	prol	0.7667	0.5528	0.5215
	ash	0.2450	0.4307	0.3979
	mag	0.4208	0.3747	0.3625
Próbka 8	od	**0.8326**	**1.3917**	**1.3387**
(*class_2*)	flav	0.6791	1.1012	1.0666
	hue	0.7691	0.9340	0.9106
	col	0.6532	0.8471	0.7583
	mag	0.2389	0.0380	0.0000

Legenda: alc = alcohol, flav = flavanoids, prol = proline, col = color_intensity, od = od280/od315_of_diluted_wines, mag = magnesium, ash = alcalinity_of_ash, hue = hue

Analiza objaśnień wygenerowanych dla zbioru Wine (Tabela VII) dostarcza kolejnych dowodów na ograniczenia metody Saliency oraz uwydatnia analityczne zalety podejść Integrated Gradients (IG) i LIME w przestrzeniach o wyższej wymiarowości. Podobnie jak w przypadku zbioru Iris, zaobserwowano, że mapy istotności generują identyczne wektory atrybucji dla różnych próbek należących do tej samej klasy (np. Próbki 1 i 4 z class_0, czy Próbki 5 i 7 z class_1). Wskazuje to na stałość lokalnego gradientu w rozległych, pofragmentowanych liniowo obszarach decyzyjnych badanej sieci MLP, co czyni metodę Saliency niewrażliwą na wewnątrzklasowe różnice poszczególnych obserwacji.

Z kolei metody IG oraz LIME oferują wysoce spójne i precyzyjne objaśnienia, które z powodzeniem ujawniają zróżnicowane profile chemiczne decydujące o klasyfikacji poszczególnych typów win. Objaśnienia te dowodzą, że w przypadku win z klasy zerowej (Próbka 1) model opiera swoje predykcje w głównej mierze na stężeniu alkoholu i proliny, podczas gdy dla klasy drugiej (Próbka 3) uwaga sieci przesuwa się całkowicie na cechy wizualne i biologiczne: intensywność barwy, odcień oraz zawartość flawonoidów.

D. Zrozumienie błędów modelu w niskowymiarowej przestrzeni cech (MNIST 2D)

W celu głębszej analizy zachowania sieci neuronowych, przeprowadzono eksperyment ze zbiorem MNIST (klasyfikacja ręcznie pisanych cyfr 0-9), w którym zredukowano wymiarowość wejścia z 784 pikseli do zaledwie dwóch, ręcznie wyekstrahowanych atrybutów geometrycznych: liczby pętli (Cecha 1) oraz wariancji szerokości znaku (Cecha 2). Wyniki atrybucji dla wybranych, reprezentatywnych próbek zestawiono w Tabeli VIII.

TABLE VIII
ATRYBUCJE DLA MODELU MNIST Z DWIEMA WYEKSTRAHOWANYMI CECHAMI GEOMETRYCZNYMI

Próbka (Prawda → Pred.)	Cecha	Saliency	IG	LIME
Próbka 4 (0 → 6)	Cecha 1	0.5811	0.9264	0.8968
Błąd	Cecha 2	0.2663	-0.0401	-0.0080
Próbka 3 (1 → 1)	Cecha 1	1.6892	2.0418	1.9878
Sukces klasyfikacyjny	Cecha 2	5.4144	4.2137	4.2392
Próbka 2 (2 → 5)	Cecha 1	0.7539	0.6489	0.7966
Błąd	Cecha 2	1.0546	0.7213	0.4843
Próbka 19 (3 → 4)	Cecha 1	1.8221	1.1454	1.1962
Błąd	Cecha 2	0.5240	0.2437	0.1510
Próbka 5 (4 → 5)	Cecha 1	0.7539	0.6670	0.6741
Błąd	Cecha 2	1.0546	0.4482	0.3531
Próbka 9 (5 → 0)	Cecha 1	0.1717	0.9857	1.0764
Błąd	Cecha 2	1.0085	1.5133	1.2754
Próbka 12 (6 → 0)	Cecha 1	0.1717	1.0180	1.1073
Błąd	Cecha 2	1.0085	1.1947	1.0249
Próbka 1 (7 → 9)	Cecha 1	0.0469	1.0803	1.0207
Błąd	Cecha 2	1.3347	0.1437	0.1254
Próbka 62 (8 → 8)	Cecha 1	0.5448	4.1389	4.0898
Sukces klasyfikacyjny	Cecha 2	0.3497	-0.3292	-0.2721
Próbka 8 (9 → 9)	Cecha 1	0.0469	1.0402	0.9990
Sukces klasyfikacyjny	Cecha 2	1.3347	0.0496	0.0248

Analiza objaśnień w silnie zredukowanej przestrzeni cech dostarcza wyjątkowo przejrzystych wniosków na temat mechaniki decyzyjnej modelu. Przede wszystkim, metody IG oraz LIME ponownie udowodniły swoją zdolność do wiernego odwzorowywania ludzkiej intuicji geometrycznej w przypadkach poprawnej klasyfikacji. Dla Próbki 3 (cyfra „1") model opierał swoją pewność niemal wyłącznie na cesze 2 (wariancja szerokości osiągnęła w LIME atrybucję 4.2392), co jest uzasadnione, ponieważ jedynka stanowi prostą linię pionową o minimalnej wariancji. Z kolei dla Próbki 62 (cyfra „8") absolutnie dominującym czynnikiem była Cecha 1 (liczba pętli, atrybucja 4.0898), podczas gdy wariancja szerokości miała charakter lekko negujący (-0.2721).

Zgromadzone dane po raz trzeci demaskują słabość map istotności (Saliency). Zestawiając ze sobą Próbkę 2 i Próbkę 5 (obie błędnie sklasyfikowane jako cyfra „5") oraz Próbkę 1 i Próbkę 8 (sklasyfikowane jako cyfra „9"), łatwo dostrzec, że wektory Saliency są wewnątrz tych par identyczne. Stanowi to kolejny dowód, że metoda ta, opierając się wyłącznie na surowym gradiencie w sieciach MLP, zwraca jedynie wektor normalny do płaszczyzny decyzyjnej przewidzianej klasy, ignorując całkowicie unikalne parametry wejściowe danej próbki.

Szczególną wartość badawczą XAI ujawniają w diagnostyce błędy modelu. W Próbce 1 (prawdziwa cyfra „7" sklasy-

fikowana jako „9”), algorytmy IG oraz LIME wskazały, że dominującym czynnikiem prowadzącym do pomyłki była Cecha 1 (liczba pętli, atrybucja IG: 1.0803). Pozwala to wysnuć wniosek, że styl pisma autora próbki (np. wyraźne, zamknięte przekreślenie siódemki) zmylił algorytm ekstrakcji cech, podając do sieci informację o istnieniu pętli, co logicznie ukierunkowało model na predykcję cyfry „9”. Podobny mechanizm zadziałał w Próbce 4, gdzie cyfra „0” została pomylona z „6” ze względu na dominujący, pozytywny wpływ zidentyfikowanej pojedynczej pętli oraz ujemną atrybucję wariancji szerokości. Narzędzia XAI pozwoliły tu udowodnić, że sam model MLP podjął decyzję racjonalną z punktu widzenia dostarczonych mu danych, a błąd leżał najprawdopodobniej na etapie ekstrakcji cech geometrycznych obrazu.

E. Wizualna interpretacja głębokich sieci CNN: Zbiór MNIST

Rozszerzeniem eksperymentów na zbiorze MNIST była analiza głębokiej sieci konwolucyjnej (CNN), w której zrezygnowano z ręcznej ekstrakcji cech na rzecz bezpośredniego przetwarzania surowych pikseli wejściowych (obrazy o wymiarach 28×28). Wprowadza to drastyczny wzrost wymiarowości problemu decyzyjnego, co wymusza zastosowanie przestrzennych form wizualizacji wektorów atrybucji. Wyniki dla wybranych próbek zaprezentowano na Rysunkach 1, 2 oraz 3.

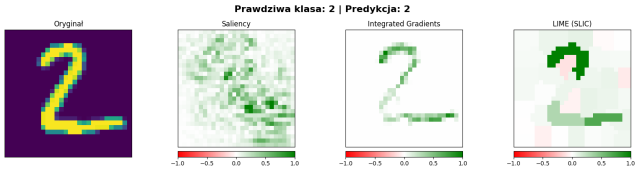


Fig. 1. Wizualizacja decyzji klasyfikacyjnej liczby "2"

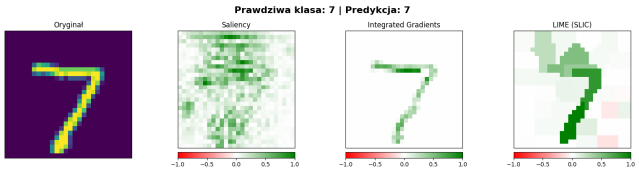


Fig. 2. Wizualizacja decyzji klasyfikacyjnej liczby "7"

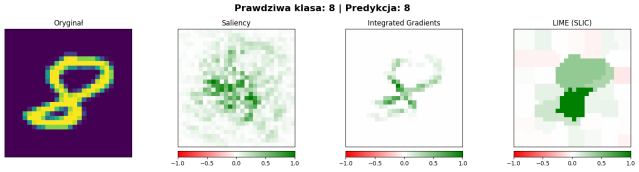


Fig. 3. Wizualizacja decyzji klasyfikacyjnej liczby "8"

Analiza zaprezentowanych map atrybucji jednoznacznie pokazuje, że głęboka sieć konwolucyjna bardzo dobrze poradziła sobie z nauką rzeczywistych kształtów odręcznie pisanych cyfr. W przeciwieństwie do prostszych klasyfikatorów, które mogłyby opierać się na pojedynczych, losowych pikselach, model CNN reaguje na konkretne struktury geometryczne i topologiczne obiektów. Na przykład w przypadku cyfry "7" (Rys. 2), metody Integrated Gradients (IG) oraz LIME idealnie pokrywają się z kształtem cyfry – poziomą kreską na górze i długą linią schodzącą w dół. Podobnie dla cyfry "2" (Rys. 1), algorytm LIME skupia swoją "uwagę" na górnym łuku oraz charakterystycznej poziomej podstawie. Proces decyzyjny dobrze poradził sobie także z predykcją dla cyfry "8" (Rys. 3). Wszystkie analizowane metody objaśniające, a w szczególności IG i LIME, wykazują najsilniejszą aktywację w centralnym punkcie przecięcia obu pętli. Oznacza to, że sieć poprawnie zidentyfikowała najbardziej unikalną cechę wizualną ósemki, czyli jej "skrzyżowanie".

Zestawienie tych trzech obrazów pozwala również zaobserwować wyraźne różnice w specyfice działania poszczególnych algorytmów XAI na prostych obrazach czarno-białych. Klasyczna metoda Saliency generuje mapy dość mocno zaszumione, co utrudnia precyzyjną interpretację. Zdecydowanie lepiej radzi sobie algorytm Integrated Gradients, który (dzięki obliczaniu całki od czarnego tła bazowego) tworzy niezwykle czysty i ostry obrys najważniejszych pikseli, dokładnie wzdłuż linii rysunku. Z kolei LIME, dzielący obraz na większe segmenty, dostarcza "blokowych", ale niezwykle intuicyjnych dla człowieka objaśnień wskazujących całe fragmenty kształtów.

W ujęciu globalnym, eksperyment ten potwierdza wysoką stabilność logiki decyzyjnej modelu. Ponieważ zbiór MNIST jest rygorystycznie ustandaryzowany i całkowicie pozbawiony tła, sieć konwolucyjna nie miała możliwości "drogi na skróty" czy uczenia się fałszywych korelacji. Musiała opanować faktyczną geometrię pisma. Wizualizacje XAI dają nam w tym przypadku twardy dowód na to, że wysoka skuteczność klasyfikacyjna modelu nie jest efektem przypadku, lecz wynika z prawidłowego, niemal "ludzkiego" skupienia się na odpowiednich krzywych i krawędziach tworzących cyfry.

F. Diagnoza błędów kontekstowych w głębokich sieciach CNN: Zbiór Imagenette

Przedostatnim etapem ewaluacji była analiza predykcji głębokiej sieci konwolucyjnej na złożonych obrazach ze zbioru Imagenette. W przeciwieństwie do cyfr na jednolitym tle, obrazy z tego zbioru charakteryzują się bogatym tłem, zmiennym oświetleniem oraz obecnością wielu obiektów pobocznych. Wybrane wyniki, zestawione na Rysunkach 4, 5, 6, 7 stanowią krytyczny test dla skuteczności algorytmów objaśniających.

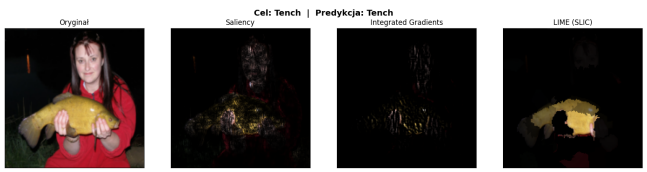


Fig. 4. Wizualizacja decyzji klasyfikacyjnej dla klasy "Tench"

Analiza poprawnych klasyfikacji (Rysunki 4, 6 i 7) pokazuje, że gdy obiekt jest dobrze wyeksponowany, model

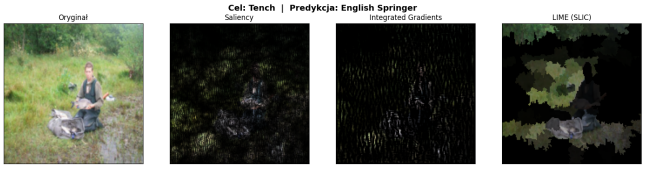


Fig. 5. Wizualizacja decyzji klasyfikacyjnej dla klasy "Tench"

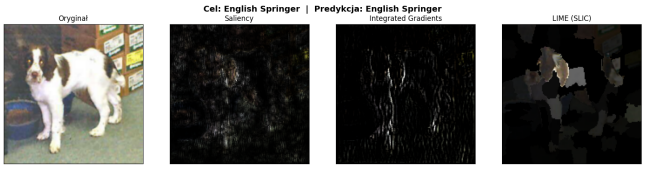


Fig. 6. Wizualizacja decyzji klasyfikacyjnej dla klasy "English Springer"

potrafi skutecznie wyłapać jego najważniejsze cechy. Na przykład przy psie rasy English Springer (Rys. 6), algorytm LIME podświetla głównie jego głowę i uszy. Oznacza to, że sieć prawidłowo uczy się charakterystycznego wzoru umaszczenia zwierzaka. Podobnie jest w przypadku radia samochodowego (Rys. 7) – metody takie jak Saliency czy Integrated Gradients wyraźnie skupiają się na krawędziach przycisków i pokręteł, ignorując gładkie, drewniane tło. Z kolei na Rysunku 4 widać, że ciemne otoczenie bardzo pomogło sieci nie rozpraszać się i skupić całą "uwagę" na łuskach i kształcie poprawnie rozpoznanego lina.

Ciekawie robi się jednak na Rysunku 5, gdzie model zaliczył sporą wpadkę i pomylił rybę z psem. Wizualizacje wygenerowane przez nasze algorytmy objaśniające pokazują, że sieć praktycznie w ogóle nie patrzyła ani na człowieka, ani na rybę. Zamiast tego jej uwaga skupiła się niemal w 100% na zielonej trawie w tle. Jest to klasyczny przykład tzw. korelacji pozornej. Zamiast nauczyć się, jak fizycznie wygląda pies, model powiązał ze sobą fakty statystyczne z danych treningowych – zauważył, że na wielu zdjęciach psy tej rasy mogły występować na tle trawy, więc zrobił sobie mylący "skrót": widzę trawę, więc to musi być pies.

Co te obserwacje mówią nam o całym modelu? Przede wszystkim potwierdzają, że sieci neuronowe bywają "leniwe". Zamiast budować pełne zrozumienie kształtu obiektu, często opierają swoje decyzje na łatwiejszych do znalezienia teksturach lub sugerują się tłem. Eksperyment ten pokazuje również, do czego najlepiej nadają się poszczególne metody XAI. O ile Saliency i Integrated Gradients świetnie wskazują na drobne detale (jak krawędzie przycisków), o tyle LIME – dzięki grupowaniu pikseli w większe bloki – w bardzo czytelny i intuicyjny sposób demaskuje błędy modelu. Podsumowując, zastosowanie tych technik pozwala nam udowodnić to, czego nie powiedzą nam zwykłe statystyki dokładności: czy nasz model rzeczywiście wie, co widzi na zdjęciu, czy tylko "zgaduje" na podstawie tła.

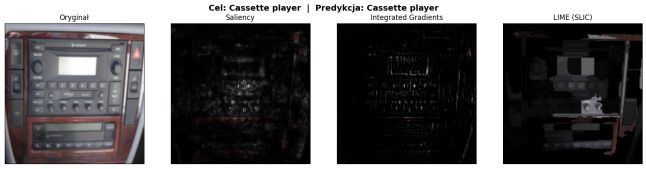


Fig. 7. Wizualizacja decyzji klasyfikacyjnej dla klasy "Cassette player"

G. Wpływ wąskiego gardła informacyjnego na logikę decyzyjną (CNN 2D Imagenette)

W celu zbadania wpływu skrajnej kompresji informacji na interpretowalność procesów wnioskowania, przeprowadzono eksperyment, w którym model przetwarzający surowe obrazy ze zbioru Imagenette, został wyposażony w tzw. wąskie gardło informacyjne – przed ostateczną warstwą klasyfikacyjną wymiarowość cech została drastycznie zredukowana do zaledwie dwóch wartości. Wyniki wizualizacji map atrybucji dla wybranych próbek przedstawiono na Rysunkach 8, 9, 10 oraz 11.

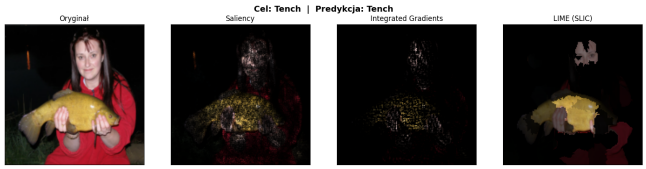


Fig. 8. Wizualizacja decyzji klasyfikacyjnej dla klasy "Tench" (model z dwiema cechami na wyjściu).

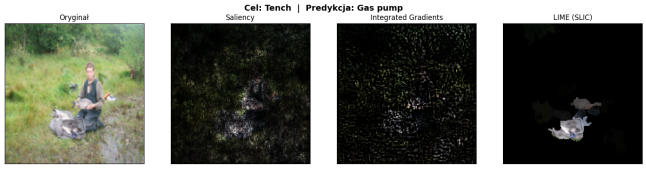


Fig. 9. Wizualizacja błędnej decyzji klasyfikacyjnej dla próbki z klasy "Tench" (model z dwiema cechami na wyjściu).



Fig. 10. Wizualizacja decyzji klasyfikacyjnej dla klasy "English Springer" (model z dwiema cechami na wyjściu).

Wprowadzenie tak drastycznego zwężenia przepływu informacji (kompresja całego obrazu do zaledwie dwóch liczb) całkowicie zmienia sposób, w jaki sieć "patrzy" na dane. Analizując przypadki, w których model odgadł poprawną klasę (Rysunki 8, 10 i 11), od razu rzuca się w oczy spadek jakości tych predykcji. W przeciwieństwie do standardowego modelu, algorytmy XAI demaskują tutaj brak jakiegokolwiek



Fig. 11. Wizualizacja decyzji klasyfikacyjnej dla klasy "Cassette player" (model z dwiema cechami na wyjściu).

głębszego zrozumienia obiektów. W przypadku psa (Rys. 10), model zignorował charakterystyczną głowę, a algorytm LIME podświetlił jedynie przypadkową plamę białej sierści i fragment łapy. Podobnie w odtwarzaczach (Rys. 11) – uwaga sieci skupiła się na gładkim fragmencie plastiku z prawej strony, omijając kluczowe przyciski. Co więcej, mapy gradientowe (Saliency i IG) stały się w tych przypadkach bardzo zaszumione i rozmyte. Oznacza to, że z powodu braku "miejsca" na informacje, model przestał rozpoznawać skomplikowane kształty, a zaczął chwytać się najprostszych, pojedynczych cech – np. jasnej plamy czy określonego koloru.

Najlepiej tę słabość oraz abstrakcyjną logikę zredukowanego modelu widać na Rysunku 9, gdzie doszło do absurdalnej wręcz pomyłki. Model uznał zdjęcie wędkarza na łonie natury za dystrybutor paliwa (Gas pump). Dlaczego tak się stało? Wyjaśnienie algorytmu LIME bezbłędnie wskazuje winowajcę: sieć skupiła całą swoją uwagę na srebrnej torbie leżącej na trawie. Przez skrajną kompresję informacji model całkowicie utracił zdolność widzenia szerszego kontekstu (las, trawa, człowiek). Wyodrębnił jedynie "metaliczny, gładki obiekt" i na podstawie tego uproszczonego sygnału na ślepo skojarzył go z elementem stacji benzynowej.

Ten eskperyment udowadnia, że zbyt wąskie gardło informacyjne zmusza sieć do korzystania z prostych skrótów myślowych. Sieć, nie mogąc przekazać dalej pełnego zarysu obiektu, uczy się reagować na pojedyncze charakterystyczne elementy, takie jak kolor. Narzędzia z dziedziny XAI pełnią tutaj rolę weryfikatora. Pokazują, że nawet jeśli taki spłaszczony model czasami zgadnie poprawną etykietę (tak jak w przypadku psa czy ryby), to robi to z zupełnie złych, często wręcz przypadkowych powodów. Eksperyment ten dobitnie podkreśla, że same metryki skuteczności nie wystarczą do oceny modelu – bez zajrzenia w głąb procesu decyzyjnego za pomocą metod objaśniających, moglibyśmy błędnie uznać, że tak prosta architektura potrafi skutecznie rozpoznawać obiekty.

V. Podsumowanie

Przeprowadzone eksperymenty dostarczają kompleksowego wglądu w mechanizmy decyzyjne modeli uczenia maszynowego oraz prezentują mocne i słabe strony popularnych algorytmów objaśniających (XAI). Na podstawie analizy zróżnicowanych zbiorów danych – od prostych problemów tabelarycznych (Iris, Wine), przez klasyfikację kształtów (MNIST), aż po złożone obrazy o wysokiej rozdzielczości (Imagenette) – można sformułować kilka kluczowych wniosków dotyczących zarówno samej interpretowalności, jak i natury sieci neuronowych.

Po pierwsze, ewaluacja jednoznacznie wykazała zróżnicowaną skuteczność i niezawodność poszczególnych metod XAI. Klasyczna metoda Saliency (oparta na surowych mapach gradientowych) okazała się wysoce zawodna w przypadku prostych sieci MLP. Generowanie identycznych wektorów atrybucji dla różnych próbek z tej samej klasy udowadnia, że Saliency nie radzi sobie z uchwyceniem lokalnych niuansów. Zdecydowanie lepsze i bardziej spójne rezultaty osiągnęły metody Integrated Gradients (IG) oraz LIME. Algorytm IG doskonale sprawdził się w precyzyjnym konturowaniu kształtów (co udowodniono na zbiorze MNIST), podczas gdy LIME, operujący na segmentach i super-pikselach, dostarczył najbardziej intuicyjnych, zrozumiałych dla człowieka objaśnień, bezbłędnie demaskując błędy na złożonych obrazach (Imagenette).

Po drugie, eksperymenty weryfikują ślepą wiarę w klasyczne metryki skuteczności (takie jak precyzja czy dokładność). Narzędzia XAI udowodniły, że modele głębokie mają silną tendencję do uczenia się "na skróty" oraz opierania się na korelacjach pozornych. Przykłady ze zbioru Imagenette, w których sieć klasyfikowała obiekt na podstawie zielonej trawy w tle lub identyfikowała dystrybutor paliwa na podstawie pojedynczego, srebrnego elementu, pokazują zjawisko, w którym model uczy się przypadkowych elementów. Model często podejmuje dobrą decyzję z zupełnie błędnych lub trywialnych powodów. Co więcej, eksperyment z zwężeniem przestrzeni cech udowodnił, że wymuszona kompresja całkowicie niszczy zdolność sieci do rozumienia geometrii obiektów.

W świetle uzyskanych wyników, naturalnym kierunkiem dla przyszłych prac jest rozszerzenie analizy o inne paradygmaty objaśniania. Szczególnie obiecujące wydaje się zastosowanie metod opartych na przykładach przeciwnych, które zamiast wskazywać istotność cech, odpowiedziałyby na pytanie, jak minimalnie zmodyfikować wejście, aby sieć zmieniła swoją predykcję. Ponadto, wartościowym obszarem badań będzie agregacja pozyskanych objaśnień lokalnych w spójne ramy globalne, co pozwoliłoby na całościową, statystyczną weryfikację zaufania do modelu przed jego wdrożeniem w krytycznych systemach decyzyjnych.

References

[1] M. T. Ribeiro, S. Singh, C. Guestrin, "Why Should I Trust You?: Explaining the Predictions of Any Classifier", KDD, 2016.
[2] M. Ancona, E. Ceolini, C. Öztireli, M. Gross, "Towards Better Understanding of Gradient-Based Attribution Methods for Deep Neural Networks", ICLR, 2018.
[3] M. Sundararajan, A. Taly, Q. Yan, "Axiomatic Attribution for Deep Networks", ICML, 2017.